.UBAeconómicas

# METODOS PREDICTIVOS
PARA LA GESTIÓN

## UNIDAD 1
### Métodos de Muestreo

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

DEPARTAMENTO PEDAGÓGICO DE MATEMÁTICA DPM
FACULTAD DE CIENCIAS ECONÓMICAS • UBA

CIUDAD AUTÓNOMA DE BUENOS AIRES

# ¿Es posible medir todos los elementos de una población?

- ¿Se puede encuestar a todos los habitantes de un país?
- ¿Se puede revisar cada producto que sale de una fábrica?
- ¿Se puede analizar cada una de las transacciones bancarias?

MEDIR TODO, CASI NUNCA ES VIABLE

**Existen Limitaciones de recursos:**

- Tiempo
- Costo
- Acceso
- Logística

**Necesitamos información confiable sin observar toda la población.**

# Motivos para recurrir al muestreo

- **Costo** — medir todo suele ser inviable por presupuesto.
  *Ej.:* encuestar a todo el padrón nacional frente a hacer una muestra estratificada.
- **Tiempo** — tomar decisiones exige resultados antes de completar un censo.
  *Ej.:* mediciones de demanda mensual para ajustar stock.
- **Accesibilidad** — no siempre es posible localizar o contactar a todos los elementos de la población.
  *Ej.:* población sin domicilio fijo (personas en situación de calle), trabajadores temporarios en obras, comunidades rurales aisladas sin registros confiables.
- **Destructividad de la medición** : la observación puede destruir la unidad.
  *Ej.:* pruebas de resistencia en piezas mecánicas o muestreo de material agrícola donde la toma destruye la muestra.

# Motivos para recurrir al muestreo

- **Carga operativa / molestias al encuestado** — encuestar a todos puede ser intrusivo o poco ético. *Ej.:* entrevistas largas sobre salud mental; Es preferible una muestra representativa.
- **Limitaciones legales o de privacidad:** los datos sensibles no siempre están disponibles para un censo. Ej.: historiales médicos o datos bancarios con acceso restringido.
- **Escala y logística:** la logística de muestrear toda la población puede ser imposible (equipamiento, personal, transporte). Ej.: mediciones ambientales en una cuenca extensa; costos y tiempos de acceso logístico.
- **Eventos raros o poblaciones dispersas:** cuando el fenómeno es caso, interesa muestrear de forma dirigida (muestreo por conglomerados, muestreo focalizado). Ej.: estudio de una enfermedad poco frecuente: muestreo por casos y controles en hospitales selectos.
- **Dinámica poblacional:** la población cambia rápido; un censo completo queda obsoleto antes de terminar. Ej.: encuestas de opinión durante una campaña electoral dinámica.

# ¿Qué es el muestreo?

El muestreo es el proceso de seleccionar una parte de la población para obtener información que permita inferir características del total.

# ¿Qué significa que una muestra sea representativa?

Una muestra es representativa cuando **refleja adecuadamente las características de la población** .

Una muestra será representativa cuando:

- ✓ No depende del tamaño de la muestra.
- ✓ Depende del método de selección
- ✓ Debe conservar la estructura de la población

Un ejemplo es si en una población de estudiantes de la facultad se sabe que un 40% estudia para contador, 30% Economía y 20% Administración y 10% Sistemas. Al tomar una muestra esas proporciones se conservan.

# Conceptos fundamentales

- **POBLACIÓN:** Conjunto total de Interés. Ej: Todos los clientes
- **MUESTRA:** Subconjunto seleccionado de la población. Ej: 500 clientes
- **PARÁMETRO:** Valor real de la población. Ej. Ingreso Promedio Real.
- **ESTADÍSTICO:** El valor calculado de la muestra. Media muestral.

# La muestra no es la población

Si tomo 100 personas hoy y 100 mañana, ¿obtengo la misma media?

NO.
Toda muestra produce una estimación distinta y posiblemente no sea igual al parámetro general.

**Error de muestreo**

**Sesgo**

# Error muestral vs Sesgo

.UBAeconómicas

En la práctica estadística, es fundamental distinguir entre la imprecisión "esperable" (error) y el error estructural que invalida nuestras conclusiones (sesgo).

| | Error Muestral | Sesgo |
|---|---|---|
| **Naturaleza** | **Aleatoria.** Es la variabilidad natural por no medir a toda la población. | **Sistemática.** Es una desviación constante en una dirección determinada. |
| **Causa** | El azar al seleccionar los elementos de la muestra. | Problemas en el diseño, en la recolección o en el instrumento. |
| **Efecto de $n$** | **Disminuye** a medida que aumentamos el tamaño de la muestra | **Persiste.** Aumentar n solo hace que el resultado errado sea más "preciso". |
| **Control** | Se cuantifica mediante el margen de error y el nivel de confianza. | Se previene con un diseño de muestreo riguroso (aleatorización). |

# Ejemplos de error muestral y sesgo

**Ejemplo de Error Muestral**

Elegimos 10 alumnos al azar y nos da 173 cm.
Análisis: Ese "3" de diferencia es error muestral.
Si en lugar de 10 alumnos tomamos 100, la media muestral probablemente estará mucho más cerca de 170.2.

**Ejemplo de Muestra Sesgada**

Queremos predecir el uso de transporte público en una ciudad.
Se realiza una encuesta únicamente a través de una aplicación de celular a las 10:00 AM.
Ahí se está excluyendo sistemáticamente a personas mayores y/o smartphone y a trabajadores que están en su jornada laboral.
Por más que se encuesten a 1.000.000 de personas el resultado seguirá sin representar la realidad de la población total.

# Fuentes de Sesgo

## 1. Sesgo de Selección

Ocurre cuando la muestra utilizada en un estudio no es representativa de la población que se pretende analizar. Esto sucede porque el método de recolección de datos favorece a ciertos grupos sobre otros.

**Ejemplo:** Realizar una encuesta de satisfacción sobre el transporte público únicamente a través de una aplicación móvil al mediodía. Se excluye sistemáticamente a las personas que no usan smartphones o a quienes trabajan en horarios de oficina, distorsionando la percepción real del servicio.

## 2. Sesgo de cobertura

Aparece cuando el marco muestral no incluye a toda la población objetivo.

**Ejemplo:** Encuesta telefónica realizada solo con teléfonos fijos sin considerar los hogares que usan solo teléfono móvil no están cubiertos.

## 3. Sesgo de No respuesta

Surge cuando una parte significativa de la muestra elegida no responde y sus opiniones difieren de los que sí contestaron.

**Ejemplo:** En un censo escolar, si los alumnos con bajo rendimiento no entregan la encuesta, los resultados de promedio estarán inflados.

# Fuentes de Sesgo

## 4. Sesgo de Medición (o de Observación)

Cuando el proceso de recolección de datos es defectuoso, ya sea por herramientas mal calibradas, preguntas de encuesta mal redactadas o errores humanos al registrar la información.

**Ejemplo:** En una fábrica, utilizar un sensor de temperatura que no ha sido calibrado en años. Si el sensor marca siempre 2°C por encima de la realidad, todos los modelos predictivos de mantenimiento basados en esos datos estarán sesgados.

## 5. Sesgo de Omisión de Variables

Surge cuando un modelo estadístico no incluye una variable importante que afecta tanto a la variable dependiente como a la independiente, creando una correlación falsa.

**Ejemplo:** Un analista que cree que una nueva política de datos mejorará la productividad solo resalta las métricas que subieron tras su implementación, ignorando el aumento en la rotación de personal o la caída en la moral del equipo.

**Título:** *Muestreo: Diseño y Análisis* > **Autor:** Sharon L. Lohr
**Editorial:** Cengage Learning (Especialmente el capítulo sobre "Sesgos y Errores en las Encuestas").

# Tipos de muestreo

CLASIFICACIÓN GENERAL

**Muestreo Probabilístico:**
Cada unidad tiene una probabilidad conocida y mayor que cero de ser seleccionada.

- Muestreo Aleatorio Simple
- Muestreo Estratificado
- Muestreo por conglomerados
- Muestreo Sistemático

**Muestreo No Probabilístico**
La probabilidad no es conocida. No permite identificar el error muestral. Se puede utilizar de modo exploratorio.
Por ej. El muestreo de bola de nieve

# Muestreo Aleatorio Simple (MAS)

Bajo este método, todos los elementos de la población, tienen la misma probabilidad de ser incluido en la muestra.

$$P(selección) = \frac{1}{N}$$

**Sin reemplazo:**
se repite el experimento  n veces para obtener las observaciones de la característica de interés.
Ej. Seleccionar productos terminados para una inspección de calidad.

**Con reemplazo:**
se extrae un elemento de la población, se observa la característica. Se devuelve el elemento a la población, se mezcla y se realiza una nueva extracción.
Ej. Simulación de fila de cliente; el tipo de cliente que puede tocar, tiene que ser con reemplazo.

# Muestreo Estratificado

Cuando se trabaja con una población donde los elementos podrían tener características diferentes (por ejemplo rangos de edad, sexo). En estos casos se toman muestras dentro de cada grupo que la conforma.
La muestra final de la población será la conformada por todas las submuestras obtenidas en cada estrato.

$$\sum_{i=1}^{L} N_i = N$$

Se usa cuando sospechas que dentro de tu organización existen grupos (estratos) que se comportan de forma muy distinta entre sí.

Necesitamos saber qué tan satisfechos están con los beneficios de los empleados, pero la opinión de un operario puede ser distinta a la de un gerente. Si hicieras un muestreo aleatorio simple, podrías terminar perdiendo la perspectiva de todos los subgrupos.

# Muestreo por Conglomerados

A diferencia del muestreo estratificado, consiste en dividir la población en grupos "naturales" (conglomerados) que serán internamente diversos pero similares entre sí. En lugar de seleccionar individuos al azar, se seleccionan **conglomerados completos** aleatoriamente y se estudian a todos los elementos que están dentro de ellos.

$$\sum_{i=1}^{M} N_i = N$$

Donde i=1, M es cada conglomerado y $N_i$ el tamaño de la muestra en cada conglomerado.

En un ejemplo similar, una encuesta de clima en una organización que se encuentra divida en 100 ciudades diferentes en todo el país. No se eligen personas al azar de toda la empresa; se eligen **oficinas enteras** (conglomerados) al azar y analizas a todo el que esté adentro.

# Muestreo Sistemático

Para una población U de tamaño N, se selecciona cada k-ésima unidad (intervalo de selección). La primer unidad es elegida al azar entre 1 y k. Se utiliza en listas largas y con una necesidad operativa rápida.
Es eficiente, pero depende de cómo esté ordenada la base, porque se puede caer en un sesgo de periodicidad en la lista.

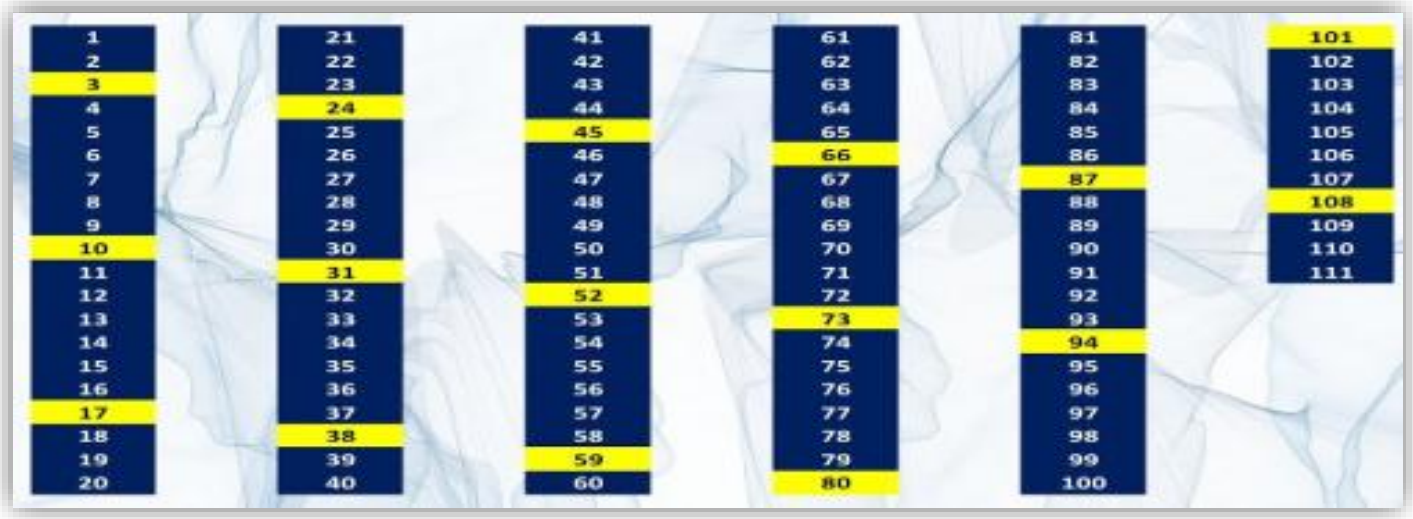


En un control de tickets de soporte, los documentos están ordenados por hora de llegada, con lo cual se asegura que se revisan todos los momentos de la jornada (mañana, tarde y noche). En un muestreo aleatorio simple, podría concentrar muchos de una franja horaria por puro azar.

# Ejemplos

**Escenario:** Una aseguradora debe auditar 10,000 siniestros liquidados. El 90% son "siniestros menores" (rotura de cristales, montos bajos y constantes), pero el 10% restante son "siniestros catastróficos" (incendios totales, con montos millonarios y altísima variabilidad).

**Muestreo Estratificado.**
Se divide por "Monto del Siniestro". Es obligatorio porque la varianza de los montos grandes es mayor. Se requiere un estrato específico para los casos catastróficos para asegurar que el riesgo financiero esté auditado.

**Escenario:** Una empresa de telecomunicaciones procesa 500 millones de paquetes de datos por hora a través de un nodo central. El equipo de ciberseguridad necesita extraer una muestra de 10.000 paquetes para realizar un análisis profundo de encabezados y detectar posibles ataques. Los paquetes llegan de forma caótica desde miles de fuentes distintas (celulares, servidores, sensores IoT) y en microsegundos.

**Muestreo Aleatorio Simple.**
implementar mediante un generador de números aleatorios en el software de captura es la única defensa contra la **estacionalidad o patrones algorítmicos** de los atacantes.

# Ejemplos

**Escenario:** Un equipo de la OMS debe estudiar enfermedades respiratorias en un asentamiento informal de 50,000 personas. No existen calles con nombre, ni números de casa, ni un censo actualizado. Sin embargo, el asentamiento está dividido visualmente por "pasillos" o sectores delimitados por accidentes geográficos (arroyos, torres de alta tensión). No hay tiempo para censar a todos antes de muestrear.

**Muestreo por Conglomerados.**
Al no existir un marco muestral (lista de personas/casas), se seleccionan los sectores o pasillos como conglomerados. Se eligen sectores al azar y se releva a todos los que viven en ese sector específico.

**Escenario:** En una planta de embotellado, se producen 500 botellas por minuto. Se detectó que el cabezal de tapado pierde presión de forma milimétrica y constante a medida que pasan las horas por el calentamiento de las piezas. Se necesita una muestra que permita trazar la curva de pérdida de presión exacta desde el inicio hasta el fin del turno de 8 horas.

**Muestreo Sistemático.**
**Reseña:** Al haber un desgaste lineal y constante, el muestreo sistemático (ej. cada 1.000 botellas) funciona como un termómetro del proceso a lo largo del tiempo, capturando la pendiente de la falla de forma precisa.

# Volviendo a los conceptos

**PARÁMETRO**
Son las características (desconocidas) de la población que son inferidos a partir de los estadísticos. Están asociados a una distribución de probabilidad de una propiedad de la población.

**ESTADÍSTICOS MUESTRALES**
Son las características observadas sobre una muestra dada. Permitirán inferir el parámetro de la población.

**DISTRIBUCIÓN DE MUESTREO**
Si tomáramos todas las muestras posibles de una población, y se calcula un estadístico, con la frecuencia observada (la cantidad de veces que asume un valor) se obtiene esa distribución.

# Inferencia

**Muestra**

$\bar{X} = media\ muestral$

$s^2 = varianza\ muestral$

$\hat{p} = proporción\ muestral$

$r = coeficiente\ de\ correlación$

La inferencia de los parámetros poblacionales será posible a partir de que cada estadístico muestral tiene una distribución muestral asociada.

**Población**

$\mu = media\ poblacional$

$\sigma^2 = varianza\ poblacional$

$P = proporción\ poblacional$

$\rho = coeficiente\ de\ correlación$

# Propiedades de los estadísticos

Es deseable que los estadísticos muestrales cumplan con las **siguientes propiedades**

- **Insesgado**: el valor esperado del estadístico es igual al parámetro poblacional. Es decir: en promedio, el estadístico coincide con el parámetro verdadero.
- **Eficiente**: Debe ser lo más estable posible entre diferentes muestras. Por lo tanto, se busca que el desvío sea lo más chico posible.
- **Consistente**: A medida que aumenta el tamaño muestral, el estimador converge hacia el parámetro.
- **Suficiente**: el estadístico muestral resulta suficiente cuando se utiliza una buena cantidad de información y ningún otro resulta mejor.

Para cumplir con estas propiedades, resulta fundamental que el tamaño de la muestra sea lo suficientemente grande.

# Propiedades de los estadísticos

Cuando n aumenta → Disminuye la varianza → Se estrechan los intervalos de confianza → Aumenta la precisión → Se reduce la probabilidad de grandes errores

Cuando n aumenta, la distribución muestral se vuelve más concentrada y por teorema Central del Límite se aproxima a la normal.
En sí, el tamaño muestral no mejora la verdad del estimador, mejora su estabilidad.

# Un ejemplo para entenderlo

**Supongamos una población con:**

- Media poblacional: μ = 100
- Desvío estándar poblacional: σ = 20

Queremos estimar μ con muestras de distinto tamaño.

**Error estándar de la media**

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

El tamaño muestral afecta directamente la variabilidad del estimador.

# Un ejemplo para entenderlo

Entonces calculemos:

| n | Calculo | Error estándar | Margen IC 95% |
|---|---|---|---|
| 25 | $SE = \frac{20}{\sqrt{25}}$ | 4 | ± 7.84 |
| 100 | $SE = \frac{20}{\sqrt{100}}$ | 2 | ± 3.92 |
| 400 | $SE = \frac{20}{\sqrt{400}}$ | 1 | ± 1.96 |

**Entonces, al aumentar la muestra, qué vimos:**

✓ El estimador sigue centrado en 100 (insesgado)

✓ La varianza disminuye cuando n aumenta

✓ El intervalo se achica

✓ Mayor n → mayor precisión

El tamaño muestral no cambia el centro. Cambia la **incertidumbre**.
En inferencia, controlar la incertidumbre es el objetivo.

# El problema inferencial

Tenemos una muestra y calculamos $\bar{X}$ → Pero queremos conocer → **μ**

**Qué tan lejos puede estar $\bar{X}$ de μ?**

↓

Los estimadores se comportan como **variables aleatorias**. Su valor fluctúa inevitablemente de una muestra a otra, generando estimaciones distintas aun cuando se utilice el mismo método.
No obstante, el conocimiento de su **distribución de muestreo** permite gestionar esta incertidumbre mediante el **Intervalo de Confianza**.

# Intervalo de confianza

El Intervalo de confianza (IC) se define como un rango de valores plausibles que, bajo una probabilidad determinada, garantiza contener el verdadero parámetro poblacional buscado.

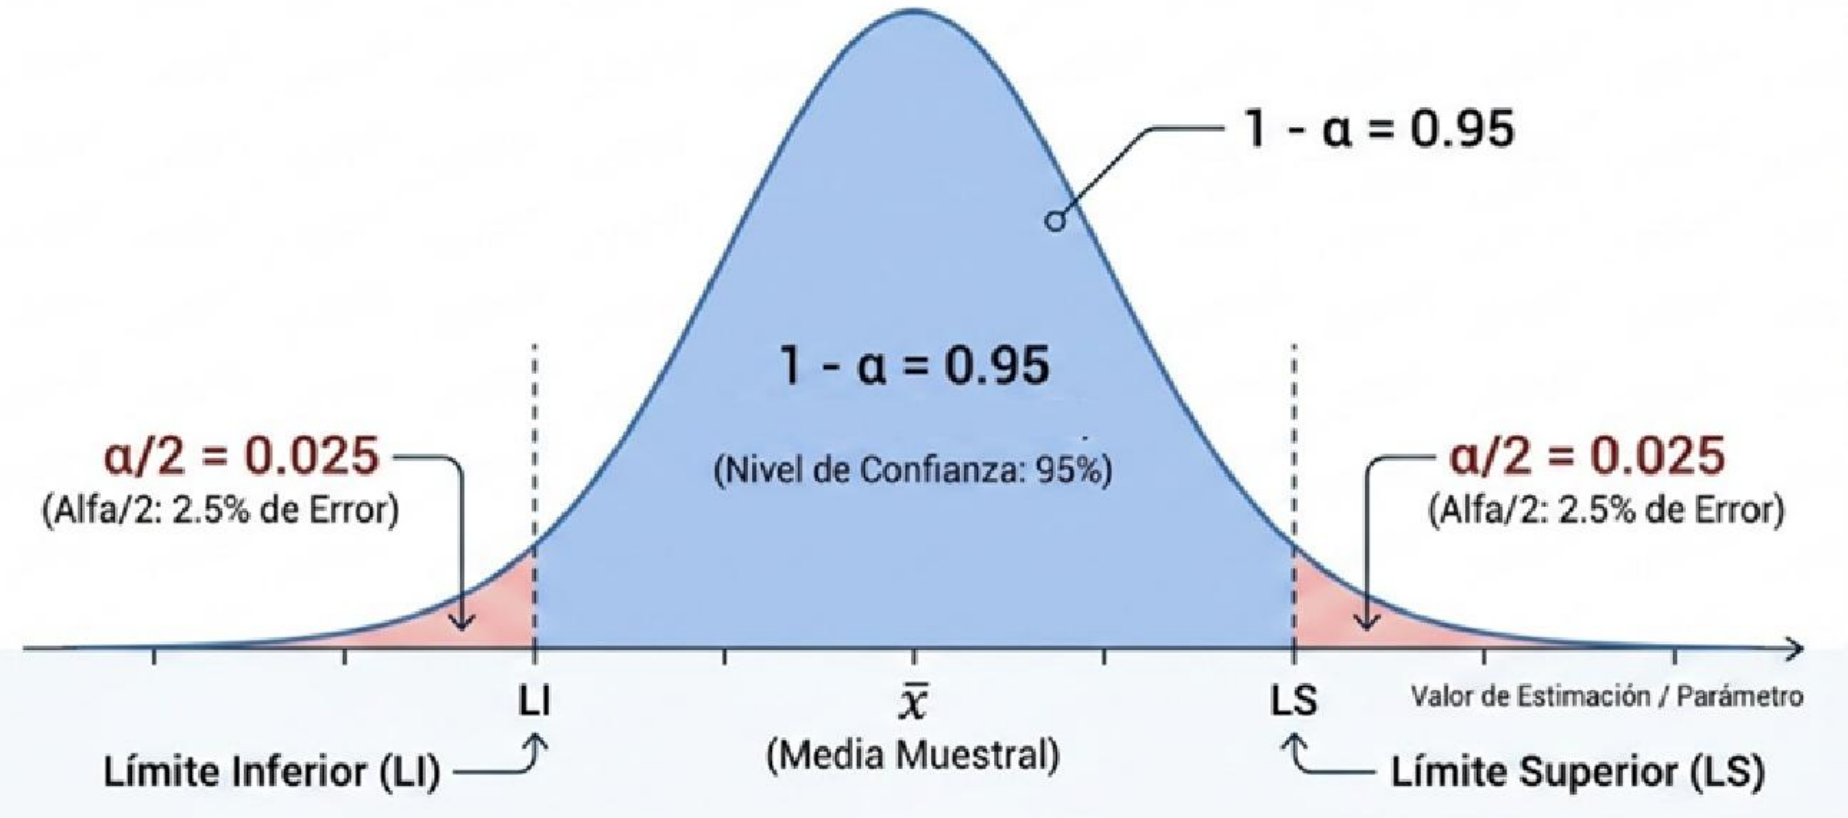

# Disminuir el Margen de error

**Población**

**Muestra**

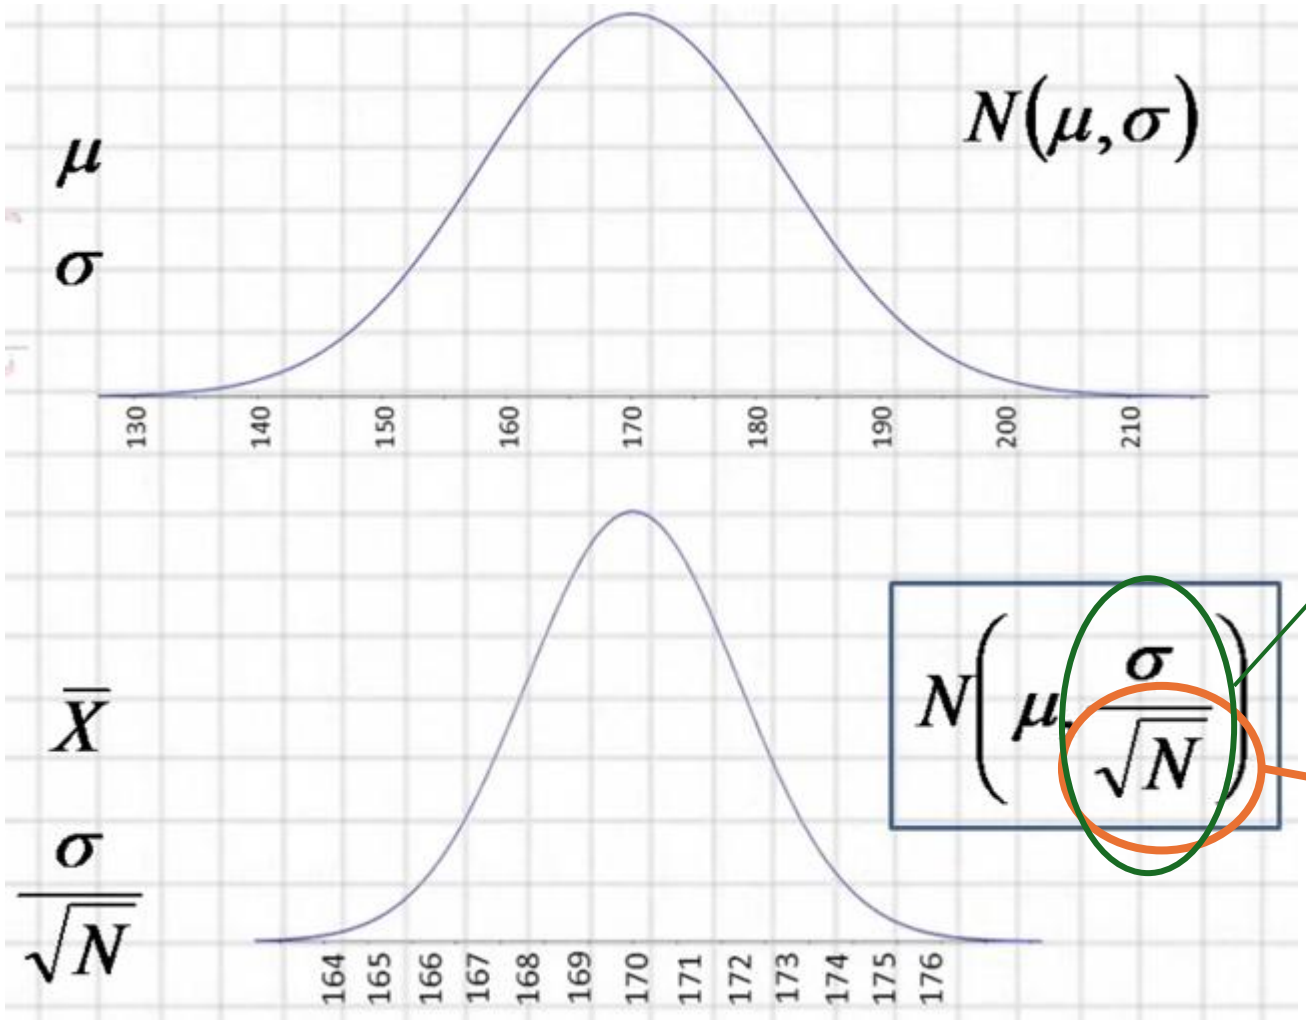


**pero ojo:** $\frac{\sigma}{\sqrt{N}}$ no mide que tan dispersos están los datos individuales, sino que tan lejos está la muestra del promedio de la población

Si el tamaño de la muestra (N) aumenta, se estrecha la curva. Mas valores cercanos a la media ➔Disminuye la **incertidumbre.**

# Objetivo: El equilibrio en la inferencia

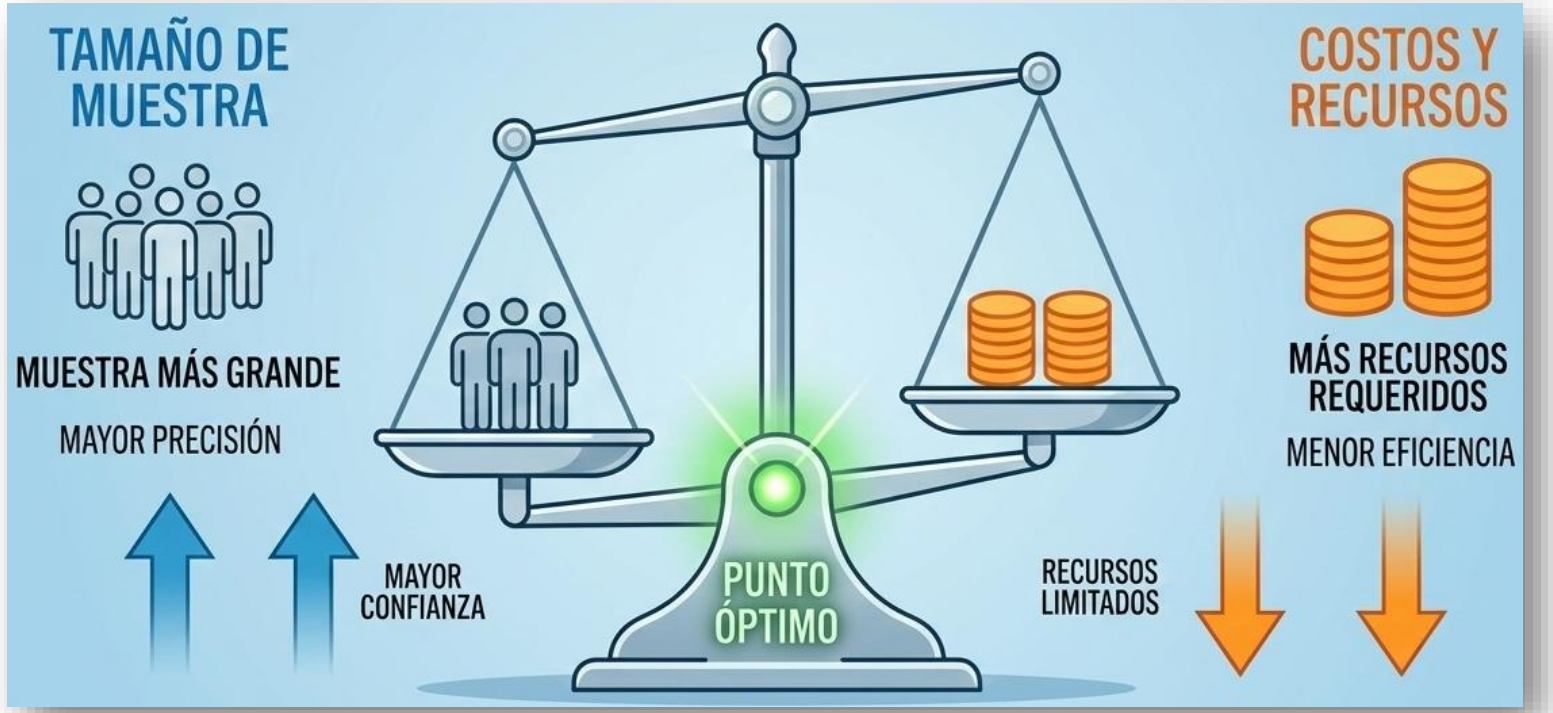


**EFICIENCIA**

- ➕ Nivel de confianza
- ➕ Precisión
- ➖ Costo

# Un ejercicio típico

Una empresa de bebidas quiere estimar el volumen promedio real servido por una llenadora automática. Toma una muestra de 64 botellas y obtiene una media muestral de 52,0 ml. El desvío poblacional del proceso es conocido y vale sigma igual a 8,0 ml. ¿Cuál es el intervalo de confianza del 95% para la media poblacional μ?

**1. Datos del problema:**

- $\bar{x} = 52,0$
- $\sigma = 8,0$ (conocido $\rightarrow$ usamos Distribución Normal $Z$)
- $n = 64$
- $1 - \alpha = 0,95 \Rightarrow \alpha = 0,05 \Rightarrow z_{\alpha/2} = 1,96$

$$P(\underbrace{\bar{X} - Z_{1-\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}}_{\text{Li}} \leq \mu \leq \underbrace{\bar{X} + Z_{1-\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}}_{\text{Ls}}) = 1 - \underbrace{\boldsymbol{\alpha}}_{\text{Percentil}}$$

# Un ejercicio típico

**2. Cálculo del Error Estándar ($EE$):**

$$EE = \frac{\sigma}{\sqrt{n}} = \frac{8,0}{\sqrt{64}} = 1,0$$

**3. Cálculo del Intervalo de Confianza ($IC$):**

$$IC = \bar{x} \pm (z_{\alpha/2} \cdot EE)$$

$$IC = 52,0 \pm (1,96 \cdot 1,0)$$

$$IC = [50,04; 53,96]$$

El intervalo de confianza del 95% para el llenado poblacional medio es de: **[50,04; 53,96]**

# Un ejercicio típico

Una empresa de logística quiere conocer con mayor precisión cuánto tarda en promedio una entrega en una de sus rutas más importantes. Para esto, analizaron 25 envíos recientes y encontraron que el tiempo promedio fue de 72 minutos, con una variabilidad (desvío) de 10 minutos.
Con esta información, quieren calcular un rango (o intervalo) donde estén seguros de que se encuentra el verdadero tiempo promedio de entrega, con un nivel de confianza del 99%.

**1. Identificación de Variables (Datos):**

- **Tamaño de la muestra ($n$):** $25$ envíos.
- **Media muestral ($\bar{x}$):** $72,0$ min.
- **Desvío muestral ($s$):** $10,0$ min.
- **Nivel de confianza:** $99\%$ ($\alpha = 0,01$).
- **Grados de libertad ($gl$):** $n - 1 = 24$.
- **Valor crítico ($t_{\alpha/2,24}$):** $2,797$ (valor de tabla T para $99\%$ y $24$ gl).

$$P\Big(\underbrace{\bar{X} - t_{n-1;1-\frac{\alpha}{2}}\frac{S}{\sqrt{n}}}_{\text{Li}} \leq \mu \leq \underbrace{\bar{X} + t_{n-1;1-\frac{\alpha}{2}}\frac{S}{\sqrt{n}}}_{\text{Ls}}\Big) = \underbrace{1 - \boldsymbol{\alpha}}_{\text{Percentil}}$$

# Un ejercicio típico

**2. Cálculo del Error Estándar ($SE$):**

$$SE = \frac{s}{\sqrt{n}} = \frac{10,0}{\sqrt{25}} = \frac{10,0}{5} = 2,0 \text{ min}$$

**3. Cálculo del Intervalo de Confianza ($IC$):**

$$IC = \bar{x} \pm (t_{crit} \cdot SE)$$

$$IC = 72,0 \pm (2,797 \cdot 2,0)$$

$$IC = 72,0 \pm 5,594$$

Con un nivel de confianza del 99% el tiempo promedio real de entregas está entre: **[66,41; 77,59]**

# El tamaño de la muestra para muestreo estratificado

Si tengo una muestra mínima determinada por cálculo de 120 observaciones, como deben ser colectadas según la estrategia adoptada.

- Aleatorio Simple → **El N calculado**
- Sistemático → **El N calculado**
- Estratificado → **¿¿¿N???**
- Por Conglomerado → **¿¿¿N???**

# Distribuir entre los estratos

1. **Proporcional:** Es la más frecuente. Cada estrato recibe un número de observaciones proporcional a su tamaño en la población.

2. **Simple (Igualitaria):** Dividir los 120 por el número de estratos.

   Cuando las varianzas de los estratos son muy distintas entre si, se buscan optimizar recursos, no tomar observaciones de más, sobre estratos cuya variable no cambian mucho.

3. **Óptima (Neyman):** Se asignan más casos a los estratos que tienen mayor variabilidad (dispersión), buscando la estimación sea aún más precisa.

$$n_h = n \frac{N_h . \sigma}{\sum_{i=1}^{L} (n_{i.} . \sigma_i)}$$

# Neyman

Ejemplo: Imaginemos las 120 observaciones se dividen en dos estratos de igual tamaño.
$(N_1 = 500\ y N_2 = 500)$
pero con dispersiones distintas:
$(\sigma_1 = 10\ y \sigma_2 = 30)$
Calculamos:
Denominador común: $500 * 10 + 500 * 30 = 20000$

Estrato 1: $\frac{5000}{20000} = 30$

Estrato 2: $\frac{15000}{20000} = 90$

Aunque los grupos pesan lo mismo en la población, es un criterio para asignar el triple de la muestra a un estrato más ruidoso

El principal inconveniente de Neyman es que, para calcular $n_1$, se necesita conocer la desviación estándar previamente. Como usualmente no se conoce, se suele recurrir a: estudios piloto previos, datos históricos u otras estimaciones.

# Distribuir entre conglomerados

**1. Muestreo por conglomerados de 1 etapa**
Se selecciona un o varios conglomerados al azar y se **estudian a todos** los individuos que están dentro de ellos. Se seleccionan suficientes conglomerados hasta que la suma de sus integrantes llegue (o supere) a 120.

**2. Muestreo por conglomerados de 2 etapas**
Es lo más común en la práctica. Primero se eligen los conglomerados y, una vez dentro, se hace un segundo sorteo para elegir a algunos individuos.

**Consideraciones:**
- En la práctica, a veces se sugiere que cada estrato o conglomerado tenga 30 observaciones porque a veces es necesario hacer inferencias dentro de los subgrupos y esas cantidades permiten aplicar el TCL.
- Si los conglomerados son muy dispares entre sí, es vulnerable a la introducción de sesgos.

.UBAeconómicas

Realice las practicas del campus y cualquier consulta dirigirse al foro.