.UBAeconómicas

METODOS PREDICTIVOS
PARA LA GESTIÓN

UNIDAD 4
Regresión Lineal Múltiple

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

DEPARTAMENTO PEDAGÓGICO DE MATEMÁTICA DPM
FACULTAD DE CIENCIAS ECONÓMICAS • UBA

CIUDAD AUTÓNOMA DE BUENOS AIRES

La Regresión Lineal Simple

La Regresión Lineal Simple propone un modelo mediante cual se busca explicar el comportamiento de **una variable endógena** mediante **solo una exógena**.

¿Ejemplos....?

El Sesgo de la Variable Omitida

Supongamos que el modelo correctamente especificado tiene la siguiente forma:

$$\underset{\text{Salario}}{Y_i} = \beta_0 + \beta_1 \underset{\text{Habilidad}}{X_1} + \beta_2 \underset{\text{Educación}}{X_2} + \epsilon$$

Sin embargo, la estimación se realiza a partir del siguiente modelo

$$\underset{\text{Salario}}{Y_i} = \alpha_0 + \alpha_1 \underset{\text{Habilidad}}{X_1} + \epsilon$$

¿Cuál es el problema?

El Sesgo de la Variable Omitida

El problema está en que:

- X_2 afecta a Y_i (y no lo estoy considerando)
- X_2 está correlacionada con X_1

Entonces el efecto de X_2 condiciona y modifica X_1

Entonces:
$\alpha_1 \neq \beta_1$
α_1 queda sesgada

Si se omite una variable relevante y correlacionada, el modelo actual queda sesgado.
Es decir, su predicción quedará sub o sobreestimada **respecto del verdadero valor esperado de Y**

Modelo de Regresión Múltiple

El Modelo Lineal General: Arquitectura Base

En lugar de trazar una línea en 2D, construimos un hiperplano en múltiples dimensiones para capturar la realidad del fenómeno.

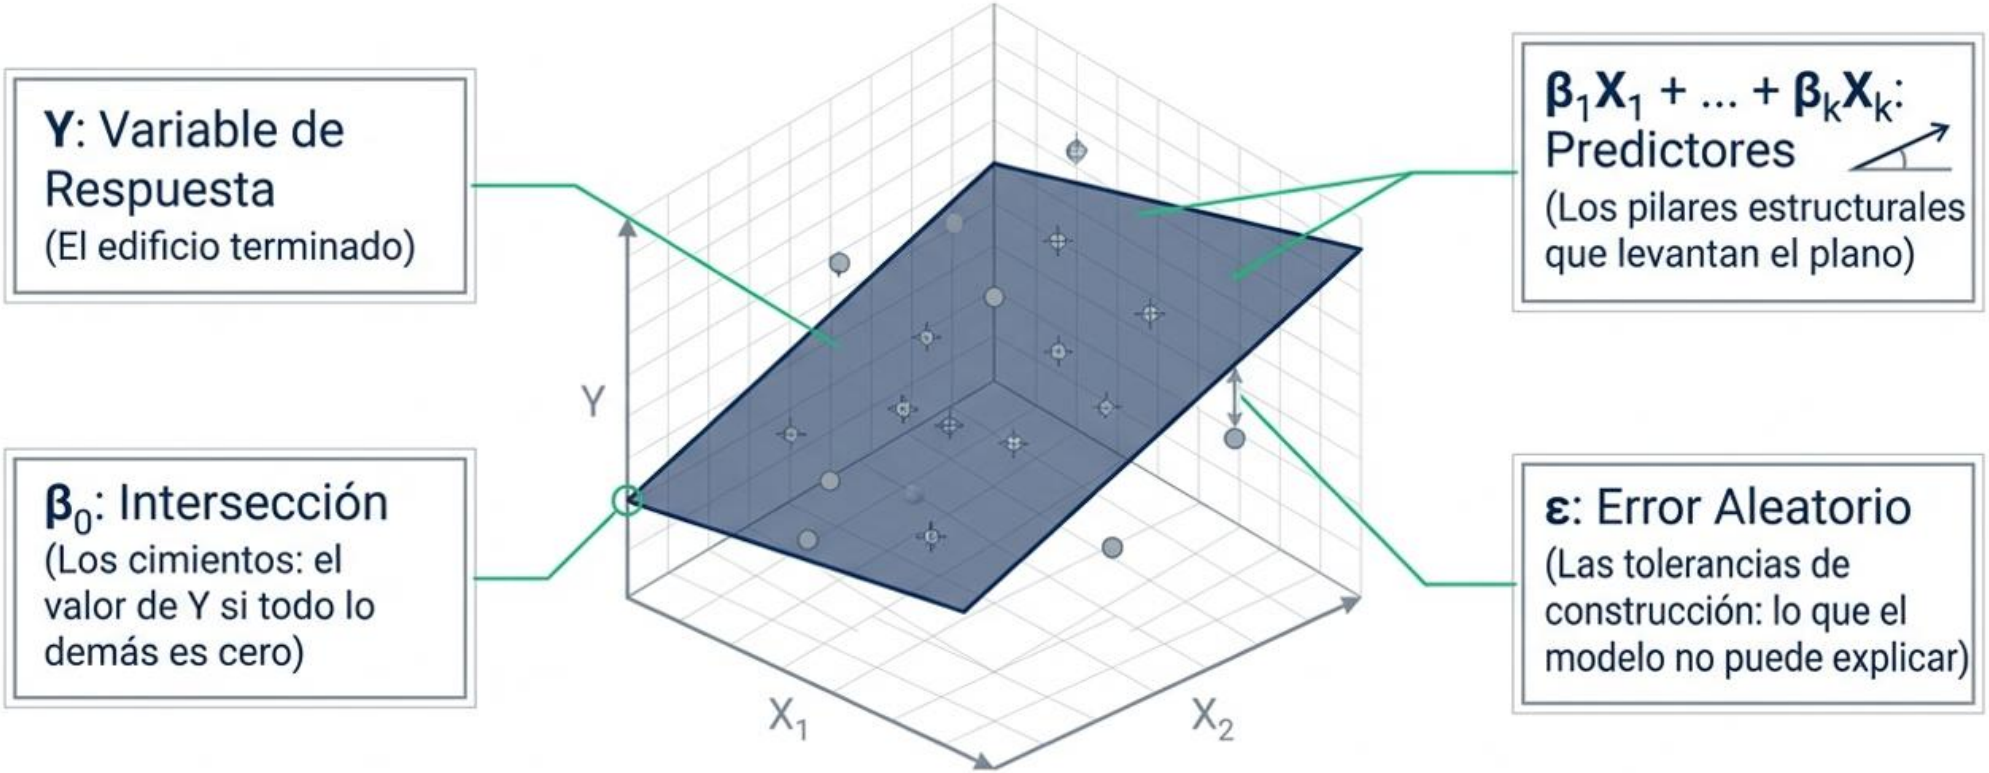

La Anatomía del Modelo Lineal

Las variables INPUT (X) / OUTPUT (Y)

$$Y_i = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \epsilon$$

β_0(Ordenada al origen): El valor base Y cuando X es cero.

$\beta_{1\ldots k}$(Pendiente): Intentan explicar el comportamiento de Y a partir de las X(s).

ϵ (Término del error Aletorio) La incertidumbre. Lo que el modelo no puede explicar

Supuestos de Gaüss-Markov

Para que las inferencias realizadas sean válidas, el mismo debe cumplir con algunos supuestos. El cumplimiento de estos garantizará que el modelo se encuentre correctamente especificado:

1. **Linealidad de los parámetros:** Significa que la función es lineal al parámetro β. Es Decir, afectan a Y en forma lineal. Aunque la función X^2no sea lineal, el modelo si lo es.

2. **No hay correlación entre los errores:** Los errores son independientes entre sí. Lo que le pasa a un dato no afecta al otro. Si el error de X_1 influye en X_2, hay autocorrelación.

3. **Los valores de X son independientes del error:** Los errores no están correlacionados con las variables explicativas. Es decir, porque la educación sea mayor, no puede afectar por cuanto me equivoco en el valor esperado.

4. **El valor medio del error es 0:** ➔ E (ε|X)=0

5. **Homocedasticidad:** La dispersión del error es constante. No importa si X tiene un valor u otro, la "incertidumbre" de la predicción debe ser la misma.

También son los Supuestos de la Regresión Lineal Simple

Supuestos de Gaüss-Markov

En los casos de Regresión Lineal Múltiple se agrega:

6. No multicolinealidad: No puede haber relaciones lineales exactas entre regresores.

Un ejemplo podría ser: Caso realista (no perfecto, pero problemático):

El precio vivienda ~ m^2 + cantidad de ambientes.

En este caso ambas variables predictoras podrían estar muy correlacionadas.
No sesga, pero podría ocasionar:

- Inestabilidad en los coeficientes.
- Signos raros
- Errores estándares altos.

MCO: Buscando el equilibrio

El modelo busca el centro geométrico que presionan sobre la variable a predecir.

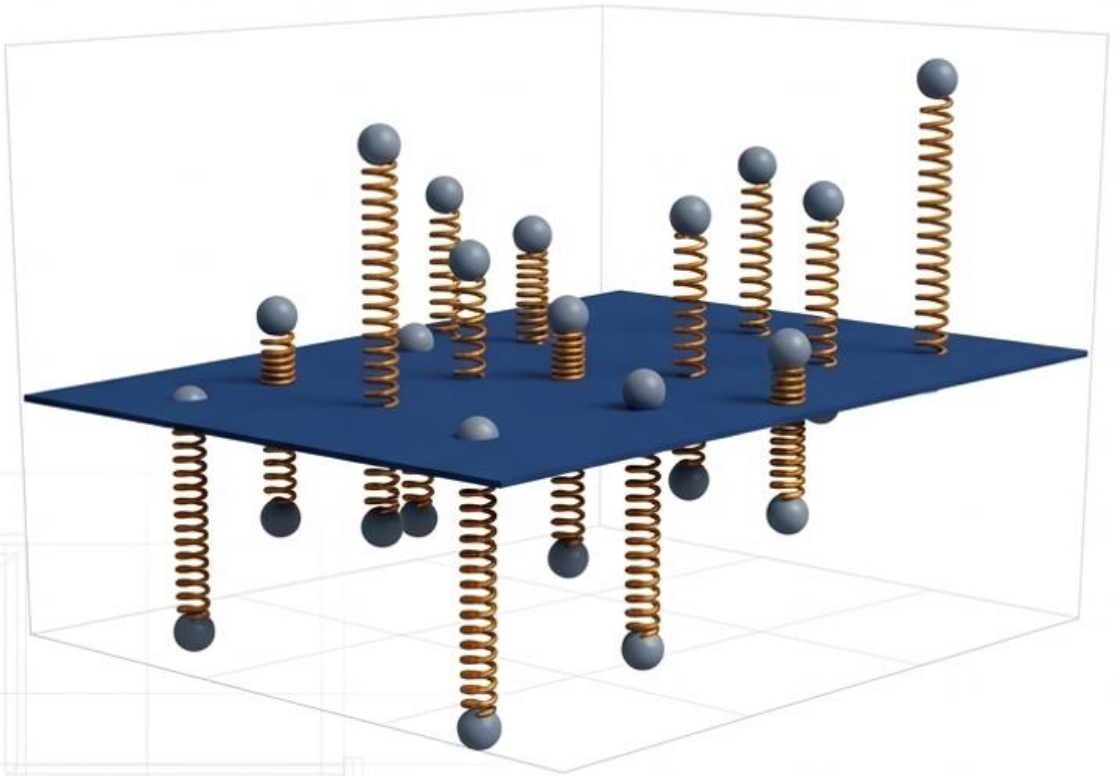

Los Resortes (Residuos $e_i = Y_i - \hat{Y}_i$)

Cada punto de datos ejerce una fuerza que tira del plano.

El Cuadrado (e_i^2)

Penaliza matemáticamente a los puntos que están muy lejos (resortes muy estirados, mayor tensión).

La Solución MCO

El plano se ajusta en inclinación y altura hasta que la tensión total de todos los resortes se minimiza (Minimizar $\sum e_i{}^2$).

Estimación de Parámetros y Aleatoriedad

El método de **Mínimos Cuadrados Ordinarios** busca que la distancia entre nuestros datos reales y la predicción sea la mínima posible. Mediante álgebra matricial, resolvemos el sistema para obtener el vector de estimadores:

$$\boxed{\hat{\beta} = (X'X)^{-1}X'Y}$$

La naturaleza de los coeficientes:

Al igual que en un modelo de regresión lineal simple, los valores que obtenemos β no son absolutos, son **estimaciones**

- **Insesgadez:** Si el modelo cumple con los supuestos de **Gaüss-Markov,** el valor esperado de las estimaciones es igual al valor real de la población. $(E[\hat{\beta}] = \beta)$.
- **Varianza y Error Estándar:** Cada estimador tiene una dispersión. Si la varianza es chica, nuestra estimación es más precisa.
- **El concepto de aleatoriedad:** Como $\hat{\beta}$ depende de la muestra aleatoria tomada, si cambiamos los datos, el coeficiente cambiará. Esta variabilidad es la que nos permite realizar luego las pruebas de significancia (test t).

Interpretación de coeficientes

Regla de Ceteris Paribus:
Un coeficiente β_j mide el impacto aislado de una sola variable sobre la variable explicada.

El cambio esperado en la variable Y por cada unidad de incremento X_1, asumiendo que el resto de las variables predictoras (X_2 y X_3) se mantienen estrictamente fijas.

Coeficiente de Determinación (R^2)

Es la métrica principal de “Bondad de ajuste”. Representa la proporción de la variación de Y que es explicada conjuntamente por el modelo propuesto

- **R^2 cerca de 1**: el plano se desarrolla cerca de todos los datos.
- **R^2 cerca de 0:** el modelo no aporta valor predictivo sobre usar simplemente el promedio histórico.

La trampa del R^2 y la parsimonia

<u>El problema:</u>
Empíricamente al añadir cualquier variable al modelo siempre hará que el $\boldsymbol{R^2}$ aumente aún cuando la variable adicional sea ruido. Esto tiende a complejizar innecesariamente el modelo, aumentando **el costo computacional y la inestabilidad.**

<u>El criterio de parsimonia:</u>
Priorizar los modelos simples que expliquen bien los datos con la menor cantidad de variables posibles.

<u>La solución:</u>
El $R^2_{ajustado}$ equilibra la balanza introduciendo un costo estadístico por cada parámetro (k) añadido.
Si se agrega una variable inútil la penalización matemática será mayor que la ganancia predictiva y el $\boldsymbol{R^2_{ajustado}}$ disminuirá.

$R^2_{ajustado}$

Si graficáramos el Coeficiente de determinación (R^2) y el Coeficiente de determinación ajustado ($R^2_{ajustado}$)al incluir variables predictoras adicionales se describiría una grafica como la siguiente:

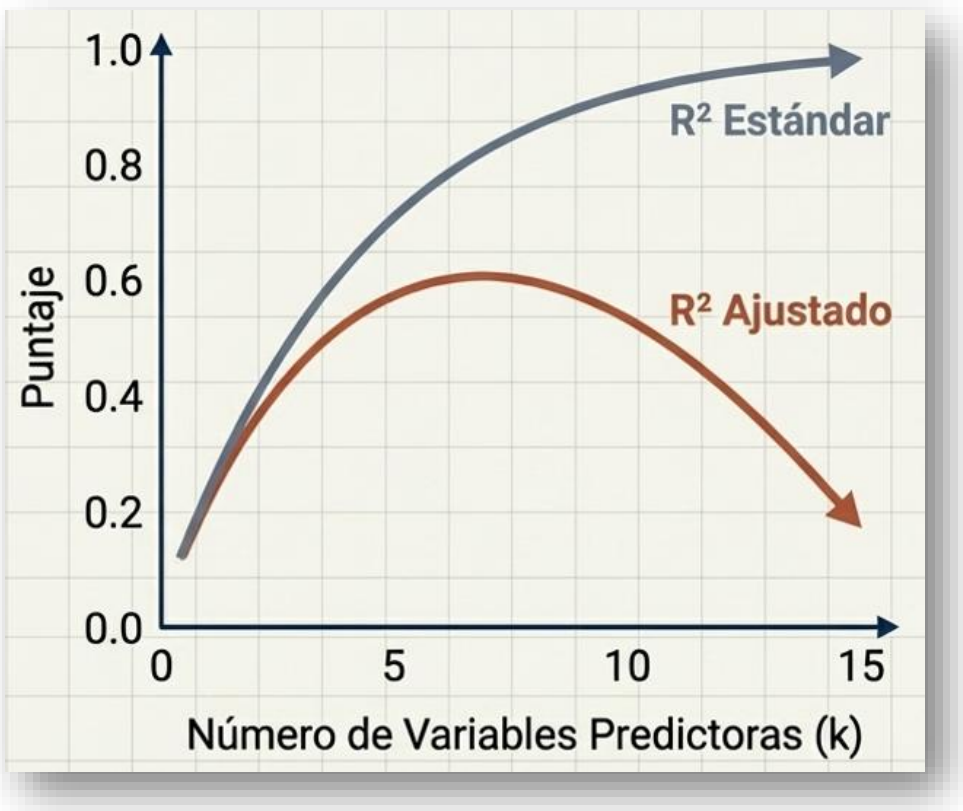

La diferencia en el cálculo del coeficiente es:

$$R^2_a = 1 - \frac{SCE}{STC} * \left[\frac{n-1}{n-(k+1)}\right]$$

El Coeficiente solo crecerá si la nueva variable reduce el error lo suficiente como para compensar la pérdida de los grados de libertad.

Pruebas de Hipótesis:
La prueba F – Evaluación del Modelo

La prueba de Significancia Global compara la variabilidad explicada del modelo contra la variabilidad del error.

$$F = \frac{\frac{SCR}{k}}{\frac{SCE}{n-k-1}}$$

- **SCR (Suma de Cuadrados de la Regresión):** La varianza que el modelo sí logra capturar.
- **SCE (Suma de Cuadrados del Error):** Es lo que el modelo no puede explicar (el ruido).
- **n:** el tamaño de la muestra.
- **k:** el número de variables independientes (regresores)

Donde el estadístico se debate entre.:

- $\boldsymbol{H_0(hipótesis\ nula)}$: $\beta_0 = \beta_1 \dots \beta_k = 0$ Ninguna variable sirve. Es lo mismo a tirar una moneda
- $\boldsymbol{H_1(hipótesis\ alternativa)}$: Al menos un β_j del modelo tiene capacidad predictiva.

Si el valor de **F** es muy grande, significa que la **variabilidad explicada es mucho mayor que el error**, lo que nos da evidencia suficiente para **rechazar la hipótesis nula** y decir que nuestro modelo es estadísticamente significativo.

Pruebas de Hipótesis:
La prueba T - El filtro de Componentes

Depuración del modelo. Evaluamos la contribución marginal de cada variable independiente.

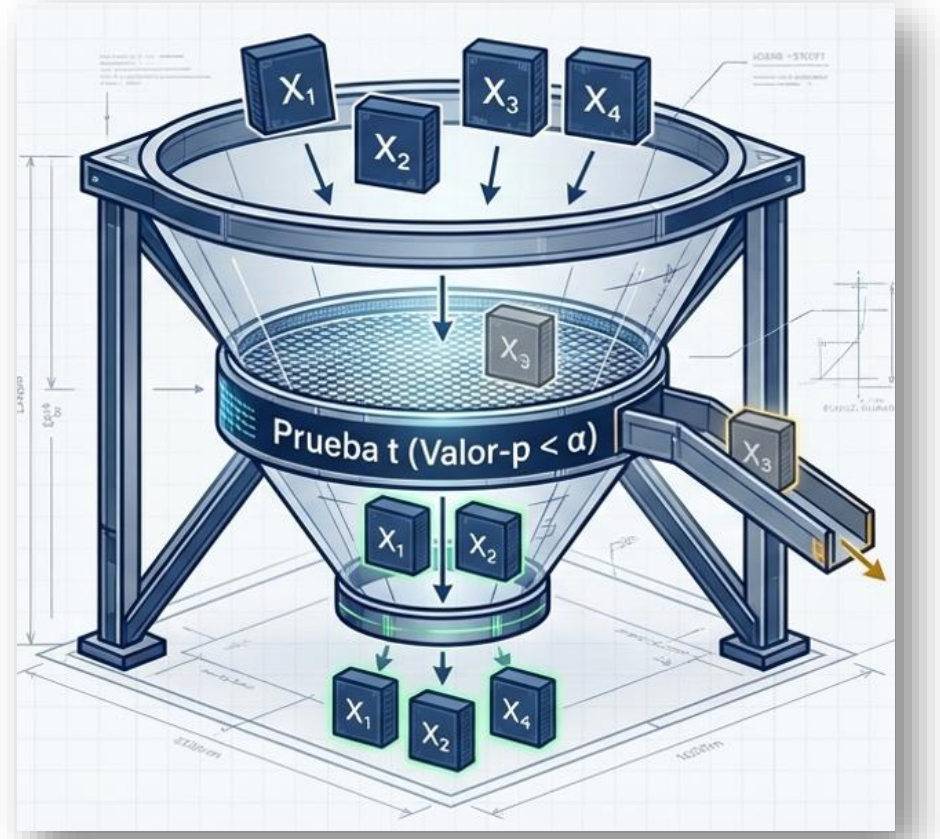

$$T = \frac{\hat{\beta}_i}{S_{\hat{\beta}_i}}$$

Divide el coeficiente estimado por su error estandar.

Donde el estadístico se debate entre.:

- $\boldsymbol{H_0(hipótesis\ nula)}$: $\beta_j = 0$
  La variable X_j no tiene relación con Y. <u>Su aporte es nulo.</u>
- $\boldsymbol{H_1(hipótesis\ altera)}$: $\beta_j \neq 0$
  La variable X_j tiene relación con Y. <u>Es estadísticamente significativa.</u>

El valor de **T** (generalmente mayor a 2 en muestras grandes) ➔ el valor **p-value es chico** (menor a 0,05). Se rechaza Hipótesis Nula.

Correlación múltiple vs. parcial

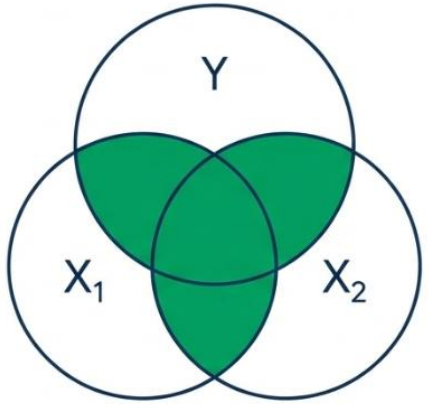

Correlación múltiple:
Intensidad de la relación entre Y y TODO el conjunto de predictores.

$$R = \sqrt{R^2}$$

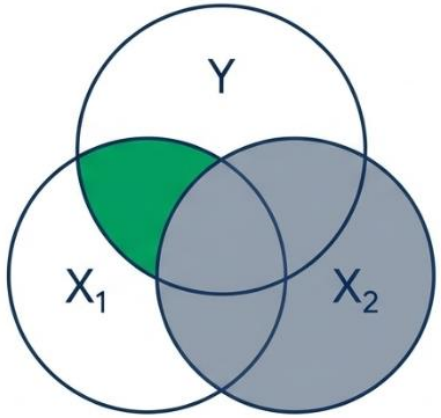

Correlación parcial:
Mide la relación neta entre un predictor e Y, purgando eliminando el efecto superpuesto de las demás variables.

$$r_p = \frac{t}{\sqrt{t^2 + (n - k - 1)}}$$

¿Para qué hacemos todo esto?

Una vez que nuestro modelo es válido (pasó las pruebas ***F*** *y* ***T***), lo usamos para generar estimaciones de $\widehat{Y}$. Sin embargo, no todas las predicciones tienen la misma confianza.

Pronóstico

Análisis de la ventana temporal:

El uso del modelo para predecir eventos futuros en principio, al tratarse una estimación puntual, debe ir acompañado de un **intervalo de predicción o confianza..**

Interpolación

Zona de seguridad:

Es la estimación de valores de ***Y*** para combinaciones de ***X*** que se encuentran **dentro del rango** de los datos originales.

Ej: si estudiamos la venta de casas entre 50 y 200 m^2 y necesitamos predecir una casa de 120 m^2

Extrapolación

Zona de riesgo:

Es la estimación de valores fuera del rango observado en las variables explicativas.

El modelo asume que la relación lineal continúa infinitamente, y esto podría no ser cierto.

Ej: Predecir con el modelo anterior una casa de 2000 m^2. Se puede usar pero es con cuidado.

Entonces...

.UBAeconómicas

"Un modelo de regresión es una ***simplificación útil*** pero no absoluta de la realidad. La validez de los pronósticos depende de que las condiciones que generaron los datos originales se mantengan constantes en el futuro. Al realizar ***extrapolaciones***, el riesgo aumenta exponencialmente: el hecho de que una relación haya sido lineal en el pasado **no asegura** que lo sea ante escenarios nunca antes vistos. La responsabilidad del analista es reportar no solo el valor estimado ($\hat{Y}$), sino también el **margen de error** y la incertidumbre asociada, entendiendo que todo parámetro estimado lleva consigo la aleatoriedad."

.UBAeconómicas

¡Muchas gracias por su atención!

Realice las practicas del campus y cualquier consulta dirigirse al foro.