

.UBAeconómicas



METODOS PREDICTIVOS PARA LA GESTIÓN

UNIDAD 4 Transformación de variables para Regresión

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

Capturar la realidad no numérica



Los modelos de regresión exigen en rigor numérico. Sin embargo, factores determinantes de la realidad como el estado civil, la ubicación geográfica u otras clasificaciones son de naturaleza cualitativa.

Variables Cualitativas


- **Variables Nominales:** Representan categorías sin orden jerárquico (género, religión, región).
- **Variables Ordinales:** Representan rangos, jerarquías. Pero no conservan una distancia clara entre las clasificaciones. Sabemos que un estudiante universitario sabe más que uno del secundario. ¿pero cuanto más?

Variables Dummy

¿Como evaluar el vínculo?



Ante variables continuas el coeficiente de Pearson permite evaluar la correlación individual entre las mismas. Sin embargo, ¿como se analizan las variables cualitativas?



¿La diferencia entre los grupos es lo suficientemente grande como para decir que no se debe al azar? El ANOVA compara la "variabilidad entre grupos" contra la "variabilidad dentro de los grupos".

Hipótesis y el valor p en ANOVA



1. **Hipótesis Nula (H_0):** Todas las medias son iguales ($\mu_0 = \mu_1 = \mu_2$). No hay efecto en la categoría.
2. **Hipótesis Alternativa (H_1):** Al menos una media es diferente a las demás. Todas las medias son iguales ($\mu_0 = \mu_1 = \mu_2$). No hay efecto en la categoría.

El ANOVA dice "hay alguien diferente", pero no dice *cuál*. Para eso se usan las pruebas *Post-Hoc* (como Tukey o Bonferroni).

El Test de Tukey (HSD): Es el más utilizado cuando queremos comparar **todos los grupos contra todos**. Calcula una "Diferencia Significativa Honesta" (HSD). Si la resta de las medias de dos grupos es mayor a ese número, entonces la diferencia es real. Se usa cuando los grupos tienen el mismo tamaño de muestra y queremos una comparación exhaustiva y balanceada.

La Corrección de Bonferroni. Es un método más "conservador" (más estricto). Simplemente divide el nivel de significancia (α) por el número de comparaciones que vas a hacer. Ej. si se hace 5 comparaciones y el (α) es 0.05, Bonferroni te obliga a que cada prueba sea menor a 0.01.

¿y entre variables cualitativas?



Técnicamente, para variables cualitativas (nominales), no hablamos de "correlación" (que implica una dirección lineal, como "si sube A, sube B"), sino de **asociación** o **dependencia**.

La prueba Chi-cuadrado (

Mide la **asociación** entre dos variables cualitativas.
Determina si la distribución de una variable cambia según los niveles de la otra.



Si el estadístico es alto y el p-valor bajo, existe una asociación significativa entre las variables.

Ejemplo: ¿El hábito de fumar (Sí/No) depende del Género (M/F)? No hay una "dirección" (no puedes decir que ser hombre es "más" que ser mujer), solo hay una relación de dependencia.

Variables Dummy en clasificaciones binarias



Para introducir información no numérica en un modelo, es preciso que la misma sea vectorizada. Mientras la información sea dicotómica (o binaria), la transformación es sencilla: 1 y 0.


Género		$\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$
Femenino	→	
Masculino	→	$\begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}$
Femenino		
Región		$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$
Norte	→	
Sur	→	$\begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}$
Norte	→	$\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$

$$D_i = \begin{cases} 1 & \text{si la condición se cumple,} \\ 0 & \text{en caso contrario} \end{cases}$$

Variables Dummy con categorías múltiples



Cuando las categorías son múltiples, una clasificación dummy con tantas variables como categorías halla genera un problema de colinealidad perfecta.



$$\text{Regla de Oro} = g - 1$$

El grupo base: Todo interruptor necesita un estado de reposo. El valor 0 constante en todas las variables define el grupo de referencia (o base).

El efecto de este grupo base es absorbido íntegramente por el intercepto global β_0 .

Interpretación geométrica




Una variable dummy no altera la pendiente del modelo; provoca un salto paralelo en el plano.

$$Y = \beta_0 + \delta_0 D + \beta_1 X + u$$

Regla de Interpretación Ceteris Paribus:

δ_0 representa la diferencia exacta en el valor esperado de Y entre el grupo $D=1$ y el grupo base $D=0$, asumiendo que el resto de variables (X) permanecen constantes.

$$\delta_0 = E(Y \mid D = 1, X) - E(Y \mid D = 0, X)$$




Transformaciones a variables continuas

.UBAeconómicas




El teorema de Gauss-Markov y el estimador de MCO exigen linealidad en los parámetros (β), sin embargo no imponen restricciones sobre las variables (X). Las transformaciones de variables continuas permiten modelar relaciones sin violar los supuestos clásicos.

1. Linealizar




Convertir relaciones intrínsecamente no lineales en especificaciones lineales estimables.

2. Efectos Marginales



Permitir que la respuesta marginal dependa de la escala (rendimientos no constantes).

3. Estabilizar Varianza



Mitigar la asimetría extrema y la heterocedasticidad comprimiendo amplios rangos.

$$Y = \beta_0 + \beta_1 f(x) + \epsilon$$

Donde $f(x)$ puede ser intrínsecamente lineal mediante logaritmos, cuadrados o inversas, permitiendo modelar tasas de crecimiento y rendimientos marginales.

Logaritmos: Comprensión, Unidades y elasticidad.



Aplicar el logaritmo natural (ln) independiza el modelo de las unidades de medida originales. Además, comprime drásticamente la influencia de valores atípicos (outliers).

Dependiendo de en qué termino de la ecuación se aplique, la interpretación de la regresión será diferente:

Log-Log	Log-Nivel	Nivel-Log
$\ln(Y) = \beta_0 + \beta_1 \ln(X)$	$\ln(Y) = \beta_0 + \beta_1 X$	$Y = \beta_0 + \beta_1 \ln(X)$
Elasticidad	Semi-elasticidad	Cambio unitario por %
Un incremento del 1% en X genera un cambio estimado del β_1 % en Y.	Un aumento de 1 unidad en X cambia Y en $(100 \times \beta_1)\%$.	Un incremento del 1% en X cambia Y en $(\beta_1/100)$ unidades.


No es el valor exacto pero el resultado es una buena aproximación al porcentaje de la variación. Funciona mejor ante cambios pequeños o marginales.

Ideales, límites y soluciones



El Entorno Ideal

- Variables Positivas de Gran Magnitud: Ingresos, ventas, tamaños de población o presupuestos.
- Asimetría Positiva: Datos con "colas largas" hacia la derecha donde unas pocas observaciones masivas distorsionan la media.
- Independencia de Escala: Cuando el efecto analítico deseado es inherentemente porcentual, no absoluto.



Las Fronteras Matemáticas

- Ceros y Negativos Prohibidos: El logaritmo de cero o de un número negativo está matemáticamente indefinido. ¡Nunca aplique $\ln()$ a ganancias netas si existen periodos con pérdidas financieras!

El Ajuste Empírico (Atajo): Si una variable es mayoritariamente positiva pero contiene una fracción de valores exactos de cero, la convención estándar es sumar una constante marginal: $\ln(X + 1)$.

Aplicando y leyendo el modelo (Log-Nivel)

.UBAeconómicas



$$\widehat{\ln(wage)} = 0.417 - 0.297 \text{ female} + 0.080 \text{ educ} + \dots$$

- **Modelo Log-Lin:** La variable dependiente está en logaritmos; educ es lineal.
- **Cálculo Aproximado:**
 $\beta_{educ} = 0.080$. Ceteris paribus, un año adicional de educación se asocia a un incremento salarial aproximado del 8.0%.
- **Cálculo Exacto** (para la variable dummy female = -0.297):

$$100 \times [e^{-0.297} - 1] =$$

$$100 \times [0.743 - 1] = -25.7\%$$

(No el -29.7% que sugiere la aproximación lineal).

Funciones cuadráticas



Modelando Relaciones Parabólicas:

Los términos cuadráticos capturan rendimientos marginales crecientes o decrecientes. Permiten que el efecto de (X) sobre (Y) varíe dependiendo del nivel inicial de X .

Regla de Integridad Algebraica: Si se incluye un término cuadrático (X^2), nunca se debe omitir el término lineal (X) del modelo, sin importar su significancia estadística (valor-p). Omitirlo fuerza artificialmente que el punto de inflexión ocurra en $X=0$

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \epsilon$$

El Efecto Marginal y Punto Crítico



1. El Efecto Marginal (La Derivada):

$$\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X$$

El efecto ceteris paribus de una unidad adicional de X no es constante; depende estrictamente del valor actual de X .

2. El Punto Crítico (Punto de Inflexión):

Igualando la derivada a cero, encontramos el punto donde la relación cambia de signo (maximización/minimización).


$$X^* = \left| \frac{\beta_1}{2\beta_2} \right|$$

(Ejemplo: Si $\beta_1 > 0$ y $\beta_2 < 0$, la parábola se abre hacia abajo. X^ es el nivel que maximiza Y).*

Exponenciales



Los **modelos de crecimiento acelerado** son usados para fenómenos con tasas de crecimiento continuas y aceleradas (ej. Depreciación geométrica, crecimiento poblacional)



Modelo Multiplicativo Inicial

$$Y = \alpha e^{\beta X} \epsilon$$

Transformación lineal

$$\ln(Y) = \ln(\alpha) + \beta X + \ln(\epsilon)$$

Donde $\beta_0 = \ln(\alpha)$.

El coeficiente β se interpreta idénticamente a un modelo Log-Lin (semielasticidad)

.UBAeconómicas



¡Muchas gracias por su atención!

Realice las practicas del campus y cualquier consulta dirigirse al foro.