

.UBAeconómicas



METODOS PREDICTIVOS PARA LA GESTIÓN

UNIDAD 5 **Árboles de decisión**

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

CIUDAD AUTÓNOMA DE BUENOS AIRES

Dos problemas:




Regresión



Predecir una cantidad continua.

Regresión Lineal

Clasificación



Asignar una categoría discreta.

Regresión Logística

Propuestas
matemáticas

De la Regresión a la Lógica Algorítmica



¿Qué es un Árbol de Decisión?

A diferencia de los enfoques matemáticos, **el árbol de decisión** es un modelo que predice un valor de una variable objetivo mediante reglas de decisiones simples.




La lógica del "Si / Entonces": construye una jerarquía de decisiones binarias siguiendo una estructura.

- **Pregunta Dicotómica:** Cada nodo evalúa una condición única (ej. *¿Es el pasajero hombre?*).
- **Respuesta Excluyente:** Solo existen dos caminos posibles (**Sí / No**).
- **Segmentación:** Cada respuesta divide los datos en dos grupos más pequeños y "más puros" que el anterior.
- **Sentencia Final:** El proceso se repite hasta llegar a una conclusión o **clase determinada**.

Estas reglas construyen un manual de instrucciones para clasificar la realidad.

Elementos de un árbol de decisión



Ejemplo



Variables Predictoras

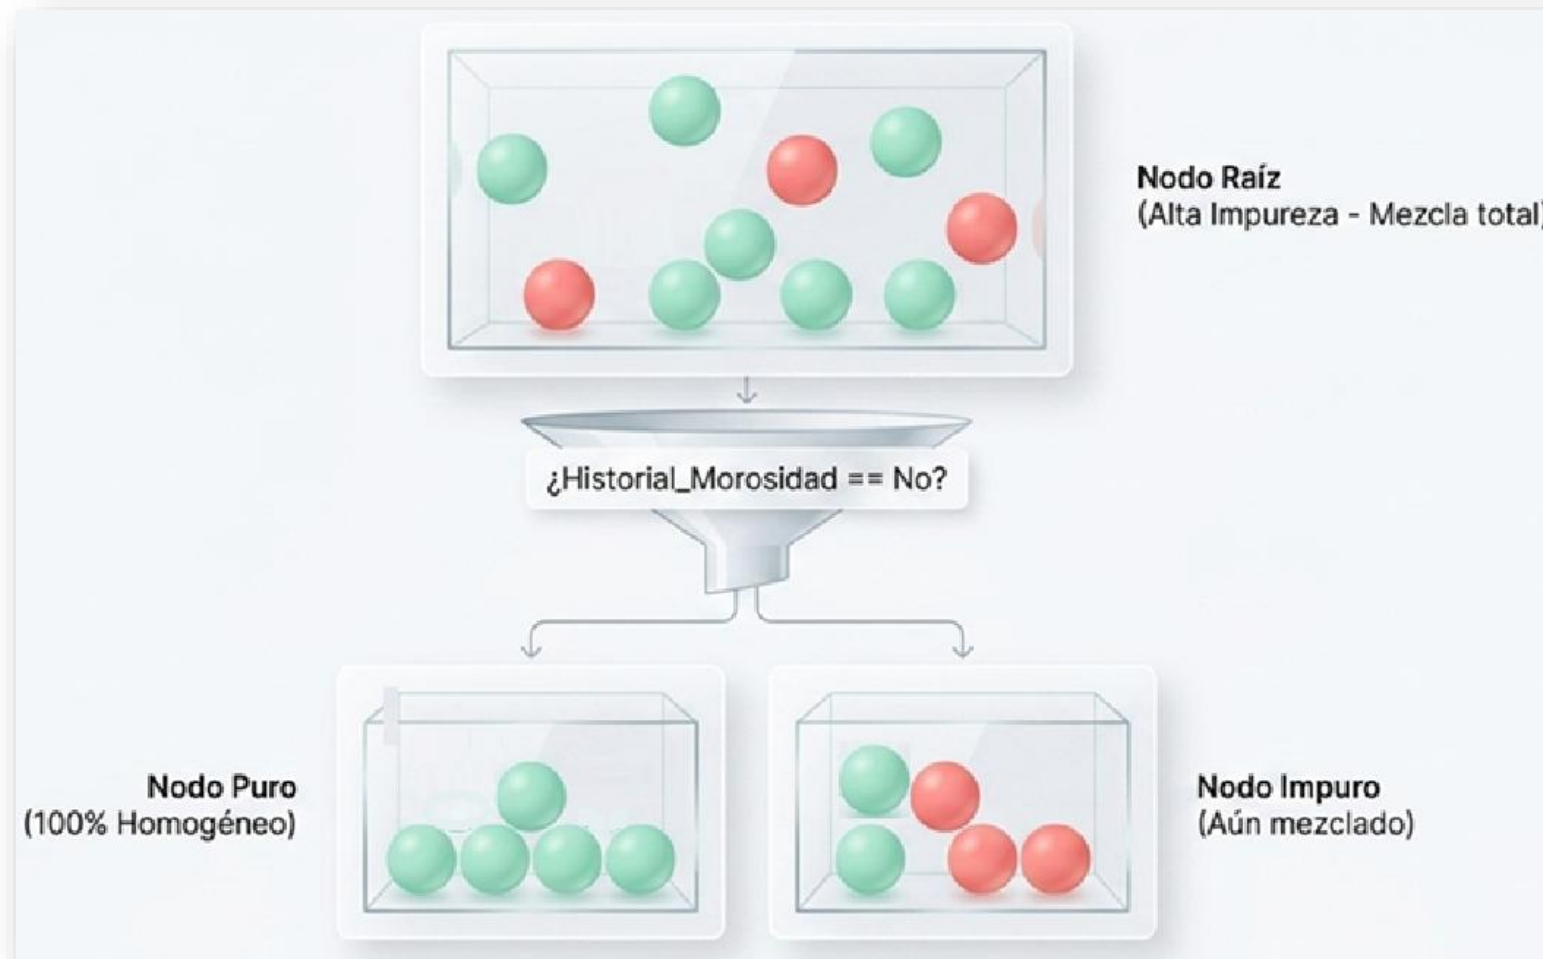
Cliente ID	Ingresos_Mensuales	Deuda_Actual	Historial_Morosidad	Estado_Crédito
C1	\$5,200	\$1,000	0	Aprobado
C2	\$4,800	\$800	0	Aprobado
C3	\$3,500	\$500	1	Aprobado
C4	\$2,100	\$200	0	Aprobado
C5	\$7,000	\$1,200	0	Aprobado
C6	\$1,800	\$600	2	Rechazado
C7	\$2,900	\$900	1	Aprobado
C8	\$8,500	\$4,500	3	Rechazado
C9	\$3,000	\$400	0	Aprobado
C10	\$2,200	\$700	2	Rechazado

Variable
objetivo
(target):

El algoritmo busca patrones matemáticos para crear su propio árbol de decisiones.

El motor del algoritmo

.UBAeconómicas



El motor del algoritmo es la **búsqueda de la pureza**: Se cortarán todos los datos una y otra vez intentando crear grupos (nodos) donde todos los individuos pertenezcan a la misma clase.

Índice Gini



El **Índice de Gini** (o Impureza de Gini) mide la probabilidad de clasificar incorrectamente un elemento elegido al azar de un conjunto, si este fuera etiquetado aleatoriamente de acuerdo con la distribución de etiquetas en ese nodo.

$$G(t) = 1 - \sum_{i=1}^c p(i|t)^2$$

- **Gini = 0**: Pureza total (todos los elementos pertenecen a la misma clase).
- **Gini = 0.5**: Impureza máxima (en un problema binario, las clases están divididas 50/50).

Donde:

- **G(t)**: Es la impureza de Gini en el nodo t.
- **C**: Es el número total de clases (en el caso del Titanic, C=2: Aprobado / Rechazado).
- **i**: Es una clase específica
- **p(i|t)**: Es la **frecuencia relativa** (proporción) de la clase i dentro del nodo t. Se calcula como:

$p(i|t) = \frac{n_{i,t}}{n_t}$ → Siendo $n_{i,t}$ los casos de la clase i en el nodo y n_t el total de casos en el nodo

Calculando Gini



Paso 1: Proporciones (p_i)

$$p_{\text{Aprobado}} = \frac{7}{10} = 0.7$$

$$p_{\text{Rechazado}} = \frac{3}{10} = 0.3$$

Paso 2: Aplicar la Fórmula

$$Gini = 1 - (0.7^2 + 0.3^2)$$

$$Gini = 1 - (0.49 + 0.09)$$

$$Gini = 1 - 0.58 = \mathbf{0.42}$$

Un Gini 0.42 indica que el nodo esta bastante mezclado (lejos de 0.0). El algoritmo ahora evaluará múltiples cortes (ej: ingresos > \$2000) buscando aquel que genere sub-nodos con un Gini promedio menor a 0.42.

Entropía



En la búsqueda de la pureza, la **entropía** como índice mide el nivel de desorden o incertidumbre en un conjunto de datos. En un nodo "puro" (donde todos los datos son de la misma clase), la entropía es 0.

$$H(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

Si las clases están mezcladas al 50%, la entropía es máxima (1).

Donde:

- **$H(S)$** : Es la Entropía del conjunto de datos S .
- **c** : El número total de clases (ej: "Aprobado" y "Reprobado" sería $\rightarrow c=2$).
- **p_i** : Es la probabilidad de que un elemento pertenezca a la clase i .

Se calcula como: $\frac{\text{elementos clase } i}{\text{Total elementos en el nodo}}$

- **$\log_2$** : Logaritmo en base 2. Se utiliza porque la información se mide típicamente en "bits".
- **Signo negativo (-)**: Se coloca al principio porque los logaritmos de fracciones (probabilidades entre 0 y 1) son negativos, y queremos que el resultado final de la entropía sea un número positivo.

Calculando Entropia



Paso 1:


- $p(\text{Aprobado}) = \frac{7}{10} = 0,70$
- $p(\text{Rechazado}) = \frac{3}{10} = 0,30$

Paso 2:


- $H = -[p_1 \log_2(p_1) + p_2 \log_2(p_2)] = -[0,7(-0,515) + 0,3(-1,737)]$
- $H = -(-0,8816) \Rightarrow H = 0,8816$

El conjunto está **mezclado**, pero con predominio de “Aprobado”. La entropía mide qué tan desordenado está el conjunto. Si todas fueran aprobadas sería 0; acá hay mezcla, por eso da alto

Evolución






Nivel 0	Nodo
Gini	0,42
Entropía	0,8816



Nivel 1	Nodo 1	Nodo 2	Pondera
Gini	0	0,48	0,24
Entropía	0	0,977	0,4855

Visualización del espacio de Variables




Visualmente, un árbol de decisión segmenta el espacio de variables trazando líneas rectas y perpendiculares a los ejes.


Geometría vs. Decisión



El Espacio Geométrico



El Árbol de Decisión (Lógica)






Lectura de Reglas (Caja Blanca)


Si los Ingresos $\leq$ \$1500 Y la Deuda $>$ \$5000
ENTONCES Crédito = Rechazado.

Esta es la ventaja del algoritmo: **su interpretabilidad**. Se puede explicar exactamente por qué se toman las decisiones.

El peligro del sobreajuste



Si se deja que un árbol siga creciendo libremente buscando la pureza extrema, es probable que cree reglas absurdas para aislar eventuales casos atípicos con tal de alcanzar un Gini de 0,0.



Sobreaajuste (Overfitting)

Memorizar vs. Generalizar




MEMORIZAR (Overfitting)

- El árbol crece demasiado, adaptándose a cada particularidad del entrenamiento.
- **Hojas diminutas** → reglas que explican un solo caso
Ejemplo:
*Si ingresos > 3000 y Deuda < 1000 y Edad = 32 y Tiene Perro → **RECHAZADO***
- Se pierde la lógica general: el árbol memoriza el ruido estadístico de la muestra.
- **Consecuencia:** bajo error en entrenamiento, pero alto error en datos nuevos (mala generalización).

GENERALIZAR (Balance Óptimo)


- Árbol más chico, con hojas que agrupan varios casos.
- Captura patrones reales, no ruido.
- **Consecuencia:** error de prueba bajo (aunque el error de entrenamiento puede ser ligeramente mayor que en overfitting).



Poda de complejidad de costos



Ante esos problemas:



En lugar de considerar cada posible sub-árbol (lo cual computacionalmente comienza a ser más y más difícil a medida que el árbol crece, volviéndose inviable en la práctica), se utiliza la **poda del eslabón más débil** (también conocida como *cost-complexity pruning* o *minimal cost-complexity pruning*).

En lugar de evaluar todas las podas posibles, se genera una secuencia de árboles cada vez más pequeños, podando iterativamente aquellos nodos que representan el "eslabón más débil", es decir, aquellos cuya eliminación produce la mayor mejora en la capacidad de generalización por unidad de aumento de la complejidad.




El trabajo del analista

La tarea clave del analista luego del pretratamiento es ajustar hiperparámetros del modelo.


Parámetro	Acción	Implicancia
Max_Depth (Profundidad máxima)	Obliga al árbol a detenerse después de un número específico de niveles.	Corta las ramas largas para evitar sobreajuste.
Min_samples_leaf (Muestras mínimas por hoja)	Prohíbe crear una hoja si no contiene al menos X cantidad de individuos.	Evita el ruido y hojas con muy pocos casos.
Min_samples_split (Muestras mínimas para dividir)	Prohíbe dividir un nodo interno si no contiene al menos X cantidad de individuos.	Evita divisiones basadas en pocos casos que no representen patrones generalizables.
Max_features (Máx. características)	Limita cuántas variables se evalúan para encontrar la mejor división en cada nodo.	Reduce el tiempo de cómputo y aumenta la aleatoriedad, útil para bosques aleatorios.
Min_impurity_decrease (Dismin. mínima de impureza)	Solo permite dividir un nodo si la ganancia en pureza supera un umbral X.	Evita divisiones poco significativas que apenas mejoran el modelo.
Max_leaf_nodes (Máximo de nodos hoja)	Limita la cantidad total de hojas que puede tener el árbol.	Controla la complejidad global del árbol de forma directa.
Class_weight (Peso de las clases)	Asigna diferentes pesos a las clases para manejar desbalanceo.	Evita que el árbol favorezca la clase mayoritaria ignorando la minoritaria.
Criterion (Criterio de división)	Elige la función para medir la calidad de una división (ej: Gini, Entropía, Error cuadrático medio).	Afecta cómo el árbol decide separar los datos.

Árboles vs. Modelos lineales

.UBAeconómicas



Triunfa si la verdadera de decisión es lineal.



Triunfa si la relación entre las características es altamente no lineal y compleja.

Los árboles son fáciles de explicar. Imitan la toma de decisiones humana, pero a veces sacrifican precisión predictiva.

.UBAeconómicas




VAMOS AL CÓDIGO

De entender la realidad...




MODELO ESTADÍSTICO TRADICIONAL

(Ej: Regresión lineal clásica)



Se usa TODO el dataset



Se estima el modelo



Se evalúa desempeño
(en los mismos datos)




Riesgo de sobreajuste
optimista

- entender relaciones
- medir impactos
- comparar variables
- detectar estructuras de los datos
 - Residuos
 - Linealidad
 - Heterocedasticidad.
- tener una base interpretable para decisiones

...a predecir



Si empleamos un enfoque similar en los árboles de decisión y en el machine learning en general... ¿cómo sabemos si el modelo efectivamente aprendió el patrón que permite implementar un modelo predictivo?



.UBAeconómicas



¡Muchas gracias por su atención!

Realice las practicas del campus y cualquier consulta dirigirse al foro.