

.UBAeconómicas



MÉTODOS PREDICTIVOS

PARA LA GESTIÓN

UNIDAD 5

Regresión Logística

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

Otras decisiones...



Hasta ahora, se estudió a predecir cuánto vale una casa o cuánta lluvia caerá (Regresión). Sin embargo, en la vida real, muchas veces la pregunta no es “¿cuánto?” sino “¿qué?”


- ¿Este cliente se va a ir de la empresa?
- ¿Este mail es spam?
- ¿Este crédito es riesgoso?
- ¿Va a llover mañana?

Existe una “curva” que estadísticamente sostiene este tipo de decisiones en muchos campos como la medicina, el marketing, etc.

El problema de la recta



Si la variable a predecir es binaria (0 o 1), la regresión lineal presenta algunos problemas:



Límites Rotos

Una recta no tiene fronteras. Inevitablemente predecirá probabilidades matemáticamente imposibles (ej. -15% o 120%).

Varianza no Constante


En datos dicotómicos, el error no se distribuye de forma normal ni constante, violando los supuestos del modelo lineal.

Sensibilidad a Extremos

Un solo valor atípico (outlier) altera drásticamente el ángulo de la recta, arruinando la frontera de decisión.

La necesidad: Se requiere un modelo que restrinja la salida estrictamente al rango $[0, 1]$. Y así delimitar probabilidades reales.

La función sigmoide



La función sigmoide actúa como un compresor matemático. Toma la función lineal y la comprime para que nunca cruce el límite de 0 (fracaso absoluto) o 1 (éxito absoluto).

¿Cómo se hace para pasar de la recta a esta función sigmoide?

Probabilidad vs. Odds (chances)



Existe un puente conceptual que permite solucionar el problema. Nosotros queremos definir probabilidades, entonces:

Probabilidad



Concepto: Casos de éxito sobre el Total de casos.

$$P = \frac{\text{Éxitos}}{(\text{Éxitos} + \text{Fracasos})}$$

Ejemplo: Hay un 75% de probabilidad de compra. (0.75)

La probabilidad tiene un límite de 1.

Vs.

Odds / Chances



Concepto: Casos de éxito frente a los casos de fracaso.

$$\text{Odds} = \frac{P}{(1 - P)}$$

Ejemplo: Las chances de compra son de 3 a 1.
(0.75 / 0.25 = 3)

Los odds pueden crecer al infinito.


Odds



Los odds miden **qué tan probable es que ocurra vs que no ocurra**.

Chances (Odds)


Casos de éxito
frente a los casos
de FRACASO.



Odds = $3/1 = 3$
(3 a 1 a favor)

Entonces, por ejemplo:


- $p = 0.5 \rightarrow \text{odds} = 1 \rightarrow$ misma chance que no ocurra
- $p = 0.8 \rightarrow \text{odds} = 4 \rightarrow$ es 4 veces más probable que ocurra que no
- $p = 0.2 \rightarrow \text{odds} = 0.25 \rightarrow$ es poco probable



Cambia la escala:

- probabilidad: 0 a 1
- odds: 0 a ∞

Función Logit



Matemáticamente, la regresión logística es una regresión lineal sobre el logaritmo de las chances de que ocurra un evento.

Entonces...



La **probabilidad** es lo que necesitamos
(de 0 a 1)

$$p(x) = \frac{8}{10} = 0,8 = 80\%$$

Los **odds** es una forma intermedia
(una comparación)

$$\text{odds} = \frac{0,8}{0,2} = 4 \rightarrow 4 \text{ a } 1 \text{ a favor}$$

El **logit** permite usar una recta
(modelo lineal)

$$\text{logit} = \ln(4) = 1,39$$

Es decir, son tres formas de describir lo mismo


La regresión logística transforma probabilidades en una escala donde puede usar una recta, y después vuelve a probabilidades.”

Interpretación de coeficientes (β): Midiendo el impacto

.UBAeconómicas



Cuando X aumenta en 1 unidad



**¿Qué
sucede?**

La probabilidad final
acotada entre 0 y 1.

Ahora función sigmoide

$$\pi(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

La base del logaritmo
natural (crecimiento
exponencial).

Nuestra ecuación lineal
original, ahora atrapada
como exponente.

Nuestra ecuación
lineal acotada entre
ahora (crecimiento
exponencial).


Interpretación de coeficientes (β): Midiendo el impacto

.UBAeconómicas



$$\text{Odds Ratio (OR)} = e^{\beta}$$

Signo Positivo ($\beta > 0$)



Aumenta el logaritmo de los odds.

Incrementa la probabilidad del evento (Ej: A mayor ingreso, mayor probabilidad de compra).


Cero ($\beta = 0$)



El odds ratio es 1 ($e^0 = 1$).

La variable no tiene efecto predictivo sobre el resultado.

Signo Negativo ($\beta < 0$)



Disminuye el logaritmo de los odds.

Reduce la probabilidad del evento (Ej: A mayor edad, menor probabilidad de abandono).


Ejemplo



El Cálculo

$$\beta \rightarrow e^{\beta}$$

El coeficiente β por sí solo está en escala logarítmica. Al exponenciarlo obtenemos el **Odds Ratio (OR)**.



Ejemplo Práctico

Escenario:

Variable X = Años de antigüedad del cliente.

Evento = Renovación de póliza.


$$\text{Si } \beta = 0.405 \rightarrow e^{0.405} = 1.5$$

Lectura Directa: Por cada año adicional de antigüedad, las chances de que el cliente renueve aumentan un **50%**.

El umbral de Theresold



El modelo predice probabilidades continuas. Se impone entonces un punto de corte para clasificar.



Contexto:

El modelo produce un número continuo (ej. 0,78 o 78%). Pero el negocio requiere una decisión binaria: ¿El cliente compra o se retira sin comprar?

El punto de Corte (Cut-Off):

Por defecto, se suele utilizar el 0,5 (50%).

- Si $P \geq 0,5 \rightarrow$ Se clasifica como 1. (compra)
- Si $P \leq 0,5 \rightarrow$ Se clasifica como 0. (no compra)

Ajuste de Negocio:

El umbral es algo que puede adecuarse al negocio. En escenarios de alto riesgo (médico o financiero), el umbral puede bajarse a 0,2 o subirse a 0,8, según la tolerancia al riesgo.

El entrenamiento: Máxima Verosimilitud


.UBAeconómicas



¿Como aprende el algoritmo?

En lugar de minimizar errores al cuadrado (MCO), el modelo logístico utiliza la estimación de Máxima Verosimilitud (EMV)

Prueba coeficientes β hasta encontrar la curva que mejor separe los casos exitosos (1) de los fracasos (0)



¿Qué tan bueno es el modelo?

El pseudo R^2



En logística no tenemos "distancias" (residuos) como en la lineal, sino **Verosimilitud**.
 Es decir, ¿qué tan probable es que el modelo acierte? Para eso existen 3 criterios diferentes:

Pseudo R2	¿De dónde viene?	Rango	¿Cómo funciona?	Característica clave
McFadden	Comparación de Log-Likelihoods. Compara el modelo con uno “nulo o tonto”.	0 a <1	$R^2_{Mc\ Fadden} = 1 - \frac{LL_{mod}}{LL_{null}}$	El más riguroso. 0.2 a 0.4 es "éxito total".
Cox & Snell	Razón de Verosimilitudes	0 a ~0.75	Se basa en la razón de verosimilitud aplicada al tamaño de la muestra (n).	Según la características, es común que no llega a 1. Poco intuitivo para presentar.
Nagelkerke	Ajuste de Cox & Snell	0 a 1	Toma el índice de Cox & Snell y lo divide por su valor máximo posible.	El más amigable para reportes y presentaciones.

Significancia Global e Individual



Prueba Global: Razón de Verosimilitud (Likelihood Ratio Test)

Es el equivalente al Test F de la regresión lineal. Responde a la pregunta: ¿El modelo con variables es mejor que un modelo vacío?

Prueba de Razón de Verosimilitud (Likelihood Ratio Test)

- Si $p < 0.05 \rightarrow$ Se rechaza H_0 : El modelo es **Globalmente Significativo**.
- Si $p > 0.05 \rightarrow$ No se rechaza H_0 Los datos no tienen fuerza suficiente.

El Test de Wald (La prueba del Coeficiente)

Analiza cada variable por separado para ver si su coeficiente β es distinto de 0.

El Test de Wald (La prueba del Coeficiente)

- Si $p < 0.05 \rightarrow$ Se rechaza H_0 : El IC del coeficiente no incluye al 0
- Si $p > 0.05 \rightarrow$ No se rechaza H_0 El IC del coeficiente no incluye al 0. No se puede asegurar como influye en el modelo.

Matriz de Confusión



REALIDAD

PREDICCIÓN

	-	POSITIVO	NEGATIVO
POSITIVO		Verdadero Positivo (TP) ✓	Falso Positivo (FP) Error de tipo I ✗
NEGATIVO		Falso Negativo (FN) Error de tipo II ✗	Verdadero Negativo (TN) ✓

Verdadero Positivo (TP):

El modelo predijo el evento y ocurrió. (ÉXITO)

Ejemplo: Era un fraude y el modelo lo bloqueó. Protegimos el dinero del cliente.

Verdadero Negativo (TN):

El modelo predijo que el evento NO ocurre y NO ocurrió

Ejemplo: Era una compra legítima y el modelo la dejó pasar. El cliente operó sin problemas.

Falso Positivo (FP) - Error Tipo I:

El modelo predijo que ocurriría pero no fue así.

Ejemplo: El cliente quiso comprar un café y el modelo le bloqueó la tarjeta por error (**Falsa Alarma**). Fricción con el cliente y llamadas molestas al soporte técnico.

Falso Negativo (FN) - Error Tipo II:

El modelo no lo detectó pero si ocurrió.

Ejemplo: Un delincuente usó la tarjeta y el modelo pensó que era el dueño (**Error Crítico**). Pérdida de dinero y desconfianza en el banco.

Métricas



REALIDAD

PREDICCIÓN

	-	POSITIVO	NEGATIVO
POSITIVO		Verdadero Positivo (TP) ✓	Falso Positivo (FP) Error de tipo I ✗
NEGATIVO		Falso Negativo (FN) Error de tipo II ✗	Verdadero Negativo (TN) ✓

Exactitud (Accuracy): ¿Qué porcentaje del total adivinamos bien?

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Precisión: De los eventos predichos como positivos, cuantos lo fueron realmente.

$$Precision = \frac{TP}{TP + FP}$$

Sensibilidad (Recall): De todos los eventos positivos. ¿cuántos logamos predecir?

$$Recall = \frac{TP}{TP + FN}$$

La matriz de confusión nos obliga a mirar los errores a la cara y decidir: ¿Qué nos duele más hoy? ¿Bloquear tarjetas de más (Falsos Positivos) o dejar que nos roben (Falsos Negativos)?

¿Qué error se prefiere cometer?



El modelo no es perfecto. Aumentar la sensibilidad (**detectar más positivos**). Inevitablemente baja la especificidad (genera más falsas alarmas)




Escenario Médico / Detección de Fraude

Se prefiere **Sensibilidad Alta**.

Razón: Un Falso Positivo (falsa alarma) es preferible a un Falso Negativo (enviar a casa a un paciente enfermo o dejar pasar un fraude masivo).

Balance of Risks



Escenario Marketing / Oferta Promocional

Se prefiere **Especificidad Alta**.

Razón: Es costoso enviar promociones (Falsos Positivos) a clientes que no iban a comprar de todos modos.

No solo se minimiza el error, también se elige el error más barato para el “negocio” o “problema”

Minimizar Falsos Negativos (Prioridad: Sensibilidad/Recall)

.UBAeconómicas



Contexto: Diagnóstico de Cáncer en etapa temprana.

En salud, "perderse" un caso positivo es un alto costo.

- **Costo del FN (Crítico):** Un paciente enfermo se va a su casa creyendo que está sano. Pierde tiempo vital de tratamiento y el desenlace puede ser fatal.
- **Costo del FP (Bajo/Moderado):** Un paciente sano recibe un resultado positivo. Se asusta y debe hacerse estudios adicionales (biopsias, análisis). Es molesto y caro, pero no es fatal.
- **Estrategia:** Aquí ajustamos el modelo para que sea "muy sensible". Preferimos investigar 10 falsas alarmas antes que dejar pasar un solo caso real.

Minimizar Falsos Positivos (Prioridad: Precisión)



Contexto: Sistema de Justicia (Condena de un delito grave).

Aquí rige el principio de "presunción de inocencia".

- **Costo del FP (Crítico):** Enviar a una persona inocente a prisión. Es un error irreparable para los derechos humanos y la credibilidad del sistema.
- **Costo del FN (Moderado):** Un culpable queda libre por falta de pruebas. Es un fallo del sistema, pero socialmente se acepta como un mal menor frente a encarcelar inocentes.
- **Estrategia:** El modelo debe ser "muy seguro" antes de clasificar a alguien como culpable. Solo se "predice" positivo si la probabilidad es altísima (ej. superior al 99%).
- **Otro Ejemplo:** Filtro de spam. Prefiero que entre un correo basura (Falso Negativo) a que un correo del jefe vaya a la carpeta de spam (Falso Positivo).

El Balance de Costos (Minimizar el Costo Total)

.UBAeconómicas



Contexto: Aprobación de Créditos Bancarios.

Aquí el banco busca rentabilidad pura. Es un juego de sumas y restas.

Tipo de Error	Consecuencia Económica
Falso Positivo (FP)	Le prestamos a alguien que no paga (Default). Pérdida: El monto total del capital prestado.
Falso Negativo (FN)	Rechazamos a un cliente que sí iba a pagar. Pérdida: El interés que hubiéramos ganado (lucro cesante).

- **Análisis:** Como perder el capital (FP) suele ser mucho más caro que dejar de ganar intereses (FN), el banco prefiere ser conservador. Sin embargo, si es demasiado estricto, no presta dinero y el negocio no escala.
- **Estrategia:** Se busca un punto de equilibrio donde la **Suma de Pérdidas** sea la menor posible.
- **Otro ejemplo:** Campaña de email marketing. Si el coste de enviar el email es casi cero, me interesa alto recall (llegar a todos los posibles interesados). Si el coste es alto (enviar una muestra física cara), me interesa alta precisión (solo a los muy seguros).

Resumen



No es absoluto pero como guía:

Industria	¿Qué error es más caro?	¿Qué métrica priorizar?
Medicina / Seguridad	Falso Negativo (FN)	Recall / Sensibilidad
Justicia / Spam Filters	Falso Positivo (FP)	Precisión
Negocios / Marketing	Depende del ROI	F1-Score / Valor Económico

Siempre hay excepciones:

Campo	Regla general	Excepción
Medicina	Priorizar Recall (evitar FN)	En cirugía de alto riesgo o tratamientos agresivos, se prioriza Precisión para no operar a un sano (evitar FP).
Seguridad (antiterrorista)	Priorizar Recall (no dejar pasar al terrorista)	En control de acceso a una base nuclear, un FP (parar a un inocente) puede ser muy grave también. Se busca equilibrio.
Justicia	Priorizar Precisión (no condenar inocente)	En la libertad condicional, un FN (decir que un peligroso está listo para salir) es peor que un FP (retener a un inocente un mes más). Ahí se prioriza Recall.

.UBAeconómicas



¡Muchas gracias por su atención!

Realice las practicas del campus y cualquier consulta dirigirse al foro.