

.UBAeconómicas



METODOS PREDICTIVOS PARA LA GESTIÓN

UNIDAD 6 Cross Validation y Optimización

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

CIUDAD AUTÓNOMA DE BUENOS AIRES


.UBAeconómicas



Cross Validation

¿Cómo sabemos si nuestro modelo es bueno?

.UBAeconómicas



¿Qué puede salir mal con un único split?

.UBAeconómicas



El resultado depende fuertemente de cómo caen los datos en cada parte

- Si por azar el test tiene casos "fáciles" → error artificialmente bajo
- Si tiene casos "difíciles" → error artificialmente alto


Una sola medición termina no termina siendo del todo confiable

Estamos tomando una decisión importante sobre el modelo basándonos en una sola 'foto'."

El modelo aprendió... ¿o memorizó?



Si entrenamos el modelo mirando siempre el mismo test se puede caer en



DATA LEKAGE
(Fuga de datos)

Es cuando **información del conjunto de test (o del futuro) se filtra inadvertidamente al entrenamiento** del modelo. Usar repetidamente el **mismo conjunto de test** para ajustar hiperparámetros o tomar decisiones de diseño, el modelo termina **aprendiendo también las características específicas de ese test**. Por lo tanto, al evaluar con ese mismo test, el rendimiento termina siendo **artificialmente alto**.

- Bajo error en test (aparenta funcionar excelente)
- Confianza falsa en el modelo
- Buenas métricas en paper/presentación

El modelo memorizó el test, no aprendió a generalizar

Cuando llegan datos nuevos, el rendimiento colapsa

Resultados no reproducibles en producción

*El modelo ve información del test antes de tiempo. El resultado es una **falsa sensación de precisión**.*

Cross-validation



Para resolver este problema se suele implementar otro mecanismo que implica dividir el set de datos de entrenamiento y prueba y luego:




El conjunto de entrenamiento es dividido en k número (en general 5 o 10) de carpetas. En cada instancia se utiliza una porción distinta como test.

Al final, todos los datos fueron evaluados exactamente una vez. Esto ofrece una estimación del error mucho más robusta y e independiente del azar.

¿Qué miramos en los k errores?

.UBAeconómicas



Error



Precisión



Varianza



Confiabilidad


Un modelo con error bajo pero varianza alta puede estar sobreajustando.

Lo ideal es tener los dos bajos, pero en caso de priorizar, **la consistencia** es más valiosa porque indica que el modelo va a funcionar bien con datos que todavía no vió

Aislamiento total



Se dividen las muestras al azar antes de cualquier otra acción.



-  Sub-paso A: Usar solo los datos de entrenamiento (**TEAL**) para seleccionar las mejores variables.
- ↓
-  Sub-paso B: Entrenar el modelo con esas variables en los datos **TEAL**.
- ↓
-  Sub-paso C: Abrir la bóveda. Evaluar el modelo en el bloque **ORANGE**.

Aislamiento total: La selección de variables y el ajuste de hiperparámetros se recalculan desde cero en cada pliegue. Los datos de prueba no influyen en la construcción del modelo.

.UBAeconómicas



Optimización

¿Qué es un hiperparámetro?



Los modelos tienen **parámetros** que aprenden solos (pesos, umbrales, etc). Pero también están los **hiperparámetros** que decide el analista antes de entrenar; por ejemplo: profundidad máxima del árbol, criterio de corte en el nodo, cantidad de observaciones por hoja, tasa de aprendizaje, etc.



Su elección puede cambiar considerablemente el rendimiento del modelo.


¿Como encontrar la mejor configuración...

Hiperparámetro	Opciones	Combinaciones
criterion	4	4
max_depth	6	24
min_samples_split	3	72
min_samples_leaf	4	288

....siendo un problema que escala rápido?

Son solo 4 parámetros que debe entrenar por separado que al sumar el cross-validation de $k=5 \rightarrow 1440$ entrenamientos.

Grid Search: la búsqueda exhaustiva




Define una grilla con todos los valores posibles de cada hiperparámetro y prueba todas las combinaciones en orden e identifica el mejor rendimiento.



Garantiza encontrar el mejor dentro de la grilla

- **Costo computacional ALTO:** hay que esperar a que termine todo para tener el resultado
- **Problemas de ESCALABILIDAD.**

Random Search




Define la misma grilla pero la recorre en orden aleatorio. Parece limitado pero en la práctica el espacio de hiperparámetros no es uniforme y obtiene una buena combinación superadora a las demás.



- Cubre espacios de parámetros más rápido.
- Propone soluciones para alta ESCABILIDAD

- **Resultados inconsistentes:** Los resultados pueden variar entre ejecuciones debido a la aleatoriedad del muestreo.

Bayesian Search



Utiliza un modelo probabilístico para predecir el rendimiento de los hiperparámetros y selecciona nuevos conjuntos basándose en evaluaciones anteriores.



- Reduce el número de evaluaciones para encontrar buenos hiperparámetros.
- Propone soluciones para alta **ESCABILIDAD**

- **Complejidad:** Es más complejo de implementar.
- **Sobrecarga computacional:** Requiere cálculos adicionales para el modelo probabilístico.

.UBAeconómicas



¡Muchas gracias por su atención!

Realice las practicas del campus y cualquier consulta dirigirse al foro.