

.UBAeconómicas



METODOS PREDICTIVOS PARA LA GESTIÓN


UNIDAD 6 Ensamblés

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES



Aprendizaje supervisado

Aprendizaje supervisado



Inferencia Estadística	Predicción
Entender el por qué.	Pronosticar el qué.
Estimar parámetros poblacionales y comprender la relación estructural y significancia entre las variables.	Mapear entradas a salidas con la mayor precisión posible, sin importar la relación subyacente.
Explicabilidad y causalidad.	Precisión en datos no vistos (Generalización).



Paramétricos

Regresión Lineal / logística

No paramétricos

Árboles de decisión

Versatilidad de los árboles de decisión



Interpretabilidad vs. Precisión

.UBAeconómicas



En el caso de los árboles de decisión, si el objetivo es **explicar la decisión**, el árbol individual es una buena opción.

Sin embargo si el objetivo es la precisión es conveniente entrar en la caja negra de los **ensambles**.




El ensamble




Un árbol solo

Un **ensamble** es la combinación de múltiples modelos bases para crear un único modelo predictivo que reduce el sesgo y la varianza.



El problema está en que se resigna interpretabilidad de la decisión.



¿Por qué funciona mejor?
Un árbol solo es inestable y propenso al sobreajuste (memorizar datos). Múltiples árboles promediados cancelan sus errores individuales.


Bagging y Random Forest

Bagging (Bootstrap Aggregating)

Entrena **múltiples árboles profundos** en paralelo sobre diferentes **submuestras bootstrap** (con reemplazo). Luego, combina sus predicciones por **mayoría (clasificación) o promedio (regresión)**. Esta agregación **reduce la varianza** y combate el sobreajuste.

Random Forest

Es una variante del Bagging que **fuerza la selección aleatoria** de un subconjunto de variables en cada corte. Esto **descorrelaciona los árboles**, generando un "bosque diverso" que reduce aún más la varianza.



Original Data

Bootstrapping

Aggregating

Bagging

- ✓ Reduce la varianza y sobreajuste
- ✓ Buen rendimiento para nuevas observaciones.
- ✓ No tiene problemas con variables altamente correlacionadas.

- Pérdida total de la interpretabilidad (ya no se puede mirar un solo árbol)
- Modelo pesado en memoria.
- -Predicción lenta en tiempo real con miles de árboles.




Boosting → Ada-boost



Entrena árboles de forma **secuencial**, donde cada nuevo árbol se enfoca en **corregir los errores** del anterior mediante reponderación de observaciones q_i . La combinación ponderada reduce el **sesgo**.

Efectúa un aprendizaje secuencial:

1. Entrenar un modelo inicial.
2. Identificar errores (observaciones mal clasificadas o residuos).
3. Ajustar el siguiente modelo dando mayor importancia a esos errores.
4. Repetir y combinar los modelos.



- ✓ Reduce el sesgo.
- ✓ Suele superar a Random Forest.


- Al enfocarse en errores es sensible a Outliers y datos ruidosos.
- No se puede paralelizar, con lo cual, suele ser más lento.

Gradient Boosting



Construye árboles de forma **secuencial**. Cada nuevo árbol se entrena sobre los **residuos** (errores) del anterior, minimizando una función de pérdida mediante **descenso del gradiente**. Así se reduce progresivamente el **sesgo**.

1. Entrenar un modelo inicial.
2. Identificar errores (calcular los residuos del modelo anterior).
3. Ajustar el siguiente modelo para predecir directamente esos residuos (no las etiquetas originales).
4. Repetir y sumar las predicciones de todos los modelos.



- ✓ Buen poder predictivo.
- ✓ Altamente flexible.

- Sensible a hiperparámetros.
- Si el learning rate es muy alto, no termina de aprender si es muy chico, no termina de aprender.


XGBoost



Implementación **optimizada** de Gradient Boosting. Construye árboles secuenciales que corrigen residuos anteriores. Añade **regularización L1 y L2 (técnicas para evitar el sobreajuste (overfitting))** penalizando coeficientes o importancias demasiado altas en un modelo).

Altamente **eficiente** (paralelismo, poda, caché) y **escalable**.

1. Inicializar el modelo con una predicción base
2. Calcular los errores del modelo actual.
3. Entrenar un nuevo árbol para predecir esos residuos.
4. Actualizar la predicción sumando una parte del residuo predicho
5. Repetir los pasos 2 a 4 durante $n_{\text{estimators}}$ iteraciones.
6. Combinar (sumar) las contribuciones de todos los árboles para obtener la predicción final



- ✓ Buena Velocidad de ejecución
- ✓ Maneja datos faltantes automáticos
- ✓ La regularización previene el sobreajuste.


- Alta Complejidad técnica
- Requiere ajustar una alta cantidad de hiperparámetros para alcanzar el mayor potencial.

Stacking (Ensamble por apilamiento)



Entrena múltiples modelos base **en paralelo**. Luego, usa sus predicciones como **características de entrada** para un **meta-modelo** que aprende la mejor forma de combinarlas.

1. Entrenar varios modelos base en paralelo (ej: árbol, bagging, boosting, KNN).
2. Predecir con cada modelo base sobre los datos de entrenamiento (usando validación cruzada para evitar trampa).
3. Construir un nuevo dataset donde las predicciones de los bases son las "variables".
4. Entrenar un meta-modelo (ej: regresión lineal) para que aprenda la mejor forma de combinar esas predicciones.
5. Predecir sobre datos nuevos: los bases predicen → el meta-modelo combina → resultado final.



✓ Rompe los límites del rendimiento exprimiendo al máximo los modelos.

- Difícil de implementar con una arquitectura muy compleja.
- Alto costo computacional. Requiere varias aplicaciones corriendo en simultáneo.

.UBAeconómicas



¡Muchas gracias por su atención!

Realice las practicas del campus y cualquier consulta dirigirse al foro.