

.UBAeconómicas



MÉTODOS PREDICTIVOS PARA LA GESTIÓN

UNIDAD 6 Evaluación de Modelos

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

.UBAeconómicas



Métricas de Clasificación

Matriz de Confusión



REALIDAD

PREDICCIÓN

	-	POSITIVO	NEGATIVO
POSITIVO		Verdadero Positivo (TP) 	Falso Positivo (FP) Error de tipo I 
NEGATIVO		Falso Negativo (FN) Error de tipo II 	Verdadero Negativo (TN) 

Verdadero Positivo (TP):

El modelo predijo el evento y ocurrió. (ÉXITO)

Ejemplo: Era un fraude y el modelo lo bloqueó. Protegimos el dinero del cliente.

Verdadero Negativo (TN):

El modelo predijo que el evento NO ocurre y NO ocurrió

Ejemplo: Era una compra legítima y el modelo la dejó pasar. El cliente operó sin problemas.

Falso Positivo (FP) - Error Tipo I:

El modelo predijo que ocurriría pero no fue así.

Ejemplo: El cliente quiso comprar un café y el modelo le bloqueó la tarjeta por error (**Falsa Alarma**). Fricción con el cliente y llamadas molestas al soporte técnico.

Falso Negativo (FN) - Error Tipo II:

El modelo no lo detectó pero sí ocurrió.

Ejemplo: Un delincuente usó la tarjeta y el modelo pensó que era el dueño (**Error Crítico**). Pérdida de dinero y desconfianza en el banco.

Métricas



REALIDAD

PREDICCIÓN

	REALIDAD	
	POSITIVO	NEGATIVO
POSITIVO	Verdadero Positivo (TP) ✓	Falso Positivo (FP) Error de tipo I ✗
NEGATIVO	Falso Negativo (FN) Error de tipo II ✗	Verdadero Negativo (TN) ✓

Exactitud (Accuracy): ¿Qué porcentaje del total adivinamos bien?

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Precisión: De los eventos predichos como positivos, cuantos lo fueron realmente.

$$Precision = \frac{TP}{TP + FP}$$

Sensibilidad (Recall): De todos los eventos positivos. ¿cuántos logamos predecir?

$$Recall = \frac{TP}{TP + FN}$$

La matriz de confusión nos obliga a mirar los errores a la cara y decidir: ¿Qué nos duele más hoy? ¿Bloquear tarjetas de más (Falsos Positivos) o dejar que nos roben (Falsos Negativos)?

F1-Score




El error más común en clasificación es evaluar un modelo utilizando únicamente el **Accuracy (Exactitud)**. Este simplemente calcula el porcentaje de predicciones correctas sobre el total.

El Accuracy funciona bien **solo** si las clases están balanceadas (ej. 50% perros y 50% gatos).


¿Por qué?

Buscamos detectar una enfermedad rara que solo padece el **1%** de la población (clase positiva). Si programamos un modelo "bobo" que simplemente diga siempre que el paciente está *Sano* (clase negativa), el modelo tendrá un **99% de Accuracy**.



Científicamente parece perfecto, pero operativamente es peligroso e inútil: tiene un Recall = 0. **No detectó ningún enfermo.**

El **F1-Score** se define como la **media armónica** entre dos métricas fundamentales: la **Precisión (Precision)** y la **Sensibilidad (Recall)**.



Teníamos entonces que:

Precisión (Precision): Mide la calidad de las predicciones positivas. *De todo lo que el modelo predijo como positivo, ¿cuánto era realmente positivo?*
$$\text{Precision} = \frac{TP}{TP+FP}$$

Y luego:

Sensibilidad / Exhaustividad (Recall): Mide la cantidad de casos positivos reales que el modelo fue capaz de capturar. *De todo lo que era positivo en la realidad, ¿cuánto logró detectar el modelo?*
$$\text{Recall} = \frac{TP}{TP+FN}$$



F1-Score

Al combinar ambas mediante la media armónica, la fórmula matemática queda estructurada de la siguiente manera

$$F1\ score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

¿Por qué la media armónica y no la media aritmética simple?

Si Precision=1 y Recall=0 , el promedio simple nos daría un engañoso 0,5. Así la media armónica es mucho más estricta: penaliza severamente si cualquiera de las dos métricas se acerca a cero. En ese mismo escenario, la media armónica da un 0 rotundo. Exige que ambos componentes sean buenos para tener un puntaje alto.

F1	Interpretación Práctica
> 0.85	Excelente: El modelo es altamente confiable, detecta la gran mayoría de los casos reales y rara vez se equivoca al predecir un positivo.
0.70 - 0.85	Bueno / Aceptable: El modelo es robusto para entornos de producción, aunque tiene un margen de error controlable (algunos falsos positivos o negativos).
0.50 - 0.70	Regular: El modelo sufre un desbalance notable. O es muy "conservador" (mucha precisión pero deja pasar muchos casos) o es muy "agresivo" (detecta todo pero con muchos errores).
< 0.50	Deficiente: El modelo tiene un rendimiento pobre. Es probable que predecir al azar o usar una regla simple arroje mejores resultados estructurales.

Curva ROC y AUC




Los modelos que estudiamos no nos dicen directamente "Sí" o "NO" acerca de las opciones. Lo que hacen algoritmos como una regresión logística o un árbol es darte una **probabilidad**. Si esa probabilidad es 0.5 → es lo mismo que tirar una moneda entre dos respuestas posibles.

Por defecto, si la probabilidad es mayor o menor a 50% → podemos dar una respuesta.



Ese umbral de 0,5, es algo que podemos mover.

La **Curva ROC (Receiver Operating Characteristic)** es un gráfico que resume ese juego de evaluar **todos los umbrales posibles** (desde 0% hasta 100%) y compara la tasa de clasificaciones correctas (TPR) con los Falsos positivos (FP).




Para cada umbral, el gráfico calcula dos cosas y pone un punto en el mapa:

- **Eje Y (Sensibilidad / Verdaderos Positivos):** De todos los enfermos reales, ¿a qué porcentaje logré detectar? (Queremos que esté lo más **arriba** posible, cerca de 1).
- **Eje X (1 - Especificidad / Falsos Positivos):** De todos los sanos reales, ¿a qué porcentaje me equivoqué? (Queremos que esté lo más a la **izquierda** posible, cerca de 0).

El punto de corte óptimo es aquel que maximiza el cociente de verdaderos positivos (sensibilidad), al mismo tiempo minimiza el ratio de falsos positivos (especificidad)

Curva ROC y AUC



El estadístico AUC
(Area Under the
Curve)

- AUC = 0,5 el modelo no es mejor que un clasificador aleatorio
- AUC = 1 el modelo asigna mayores probabilidades de ocurrencia a los casos donde el suceso realmente ocurrió.

.UBAeconómicas



Métricas de Regresión


Error absoluto y cuadrático



MAE (Mean Absolute Error / Error Absoluto Medio)

Es la distancia entre la predicción del modelo y el valor real para cada dato, los hace absolutos y los promedia.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_I - \hat{y}_I|$$




Es la métrica más fácil de explicar a un cliente o directivo porque **mantiene la unidad original de la variable**. Si estás prediciendo el precio de alquileres en pesos argentinos y el MAE da 15.000, significa que en promedio el modelo se equivoca por \$15.000

Es una métrica robusta que no se vuelva loca si hay algunos datos atípicos (*outliers*) en el dataset. Trata a todos los errores por igual.

RMSE (Root Mean Squared Error/ Raiz del Error Cuadrático Medio)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_I - \hat{y}_I)^2}$$



Primero eleva cada error al cuadrado (lo que hace que los errores grandes se vuelvan grandes) y los promedia (eso sería el MSE – otra métrica). Como queda en unidades al cuadrado, le aplica la raíz cuadrada para volver a la unidad original.

El RMSE siempre va a dar un número más alto que el MAE si hay variabilidad en los errores. ¿Por qué se castiga? Imaginemos dos errores: uno de \$10 y otro de \$100. En el MAE, el de \$100 pesa 10 veces más que el de \$10. En el RMSE, al elevar al cuadrado, el error de \$100 pesa 100 veces más (\$100² = 10.000 vs \$10² = 100\$). Cometer un error grande puede ser muy malo para un negocio (ej. predecir la demanda de energía o el precio de una acción). Si el RMSE es mucho más alto que el MAE, está indicando que tu modelo comete pocos errores, pero cuando se equivoca, puede hacerlo por mucho.

Error Relativo y Coeficiente de determinación



MAPE (Mean Absolute Percentage Error / Error Porcentual Absoluto Medio)

Calcula qué porcentaje representa el error respecto al valor real de cada observación, y luego los promedia.

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Se lee directamente como un porcentaje. Es útil cuando el rango de la variable es muy amplio y permite identificar por qué porcentaje del total se equivoca sin importar la escala.

R² (Coeficiente de Determinación)

Compara a tu modelo predictivo contra el modelo más simple posible (un modelo básico que siempre predice el promedio de la variable). Mide qué porcentaje de la variabilidad de los datos logró absorber y explicar el algoritmo.

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Típicamente va de **0 a 1** (aunque en Machine Learning puede dar negativo si tu modelo es peor que el promedio).

Da una noción global de la calidad del ajuste.

.UBAeconómicas



¡Muchas gracias por su atención!

Realice las practicas del campus y cualquier consulta dirigirse al foro.