Pretratamiento de Datos

Datos Faltantes y Outliers

¿Qué es el pretratamiento de datos?

- Conjunto de técnicas para mejorar la calidad de los datos antes del análisis.
- Objetivo: obtener datos limpios, consistentes y confiables.
- Etapas:
  - Detección de errores
  - Manejo de valores faltantes
  - Identificación y tratamiento de outliers
  - Normalización y transformación

Datos faltantes: ¿Qué son?

Valores que deberían existir, pero no están registrados. El problema de los datos faltantes está presente en el análisis de datos desde los orígenes del almacenamiento.

Causas:

Errores de captura	Respuestas omitidas	Integración incompleta

Tipos de datos faltantes

Missing completely at random (MCAR): faltan completamente al azar

Missing At Random (MAR): dependen de otras variables observadas

Missing not at random (MNAR): dependen del valor faltante en sí

Valores atípicos como datos faltantes: Si se conocen los límites de las variables del conjunto de datos, los datos que caen fuera del rango esperado pueden ser tratados como datos faltantes.

Métodos para manejar datos faltantes

- Eliminación
  - Eliminación de filas (listwise)
  - Eliminación por pares (pairwise)
- Imputación simple
  - Media, mediana o moda
  - Valor constante
  - Forward/Backward fill

Ejemplo de Imputación por Media

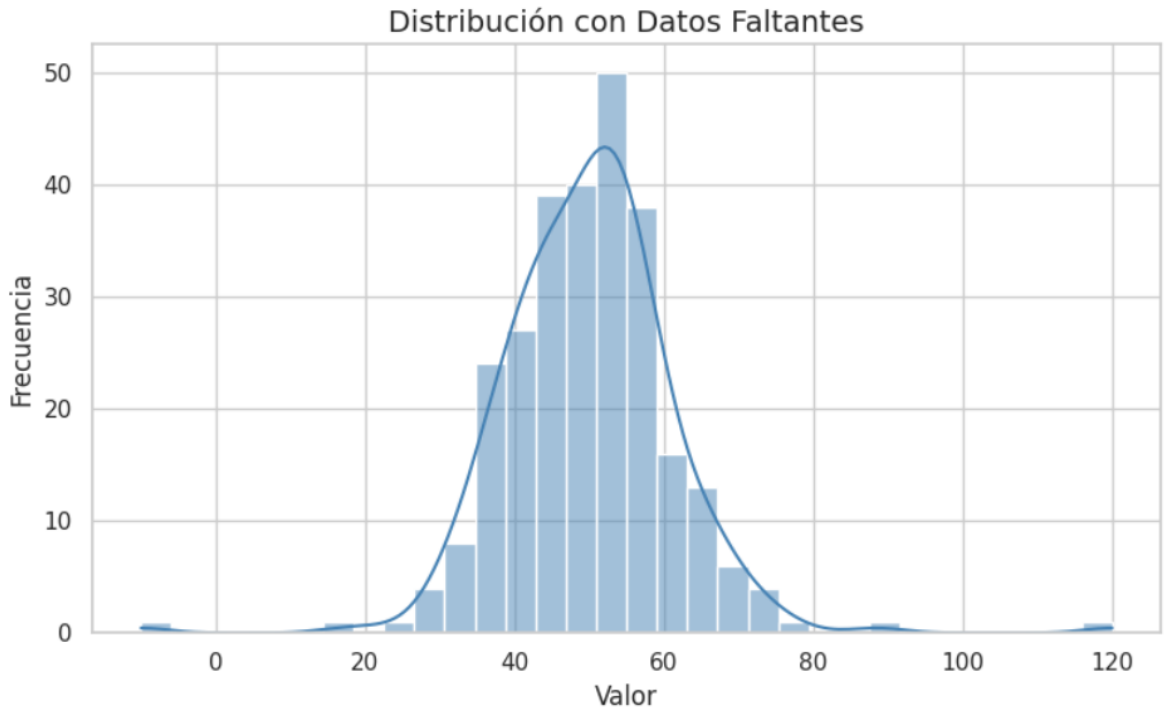

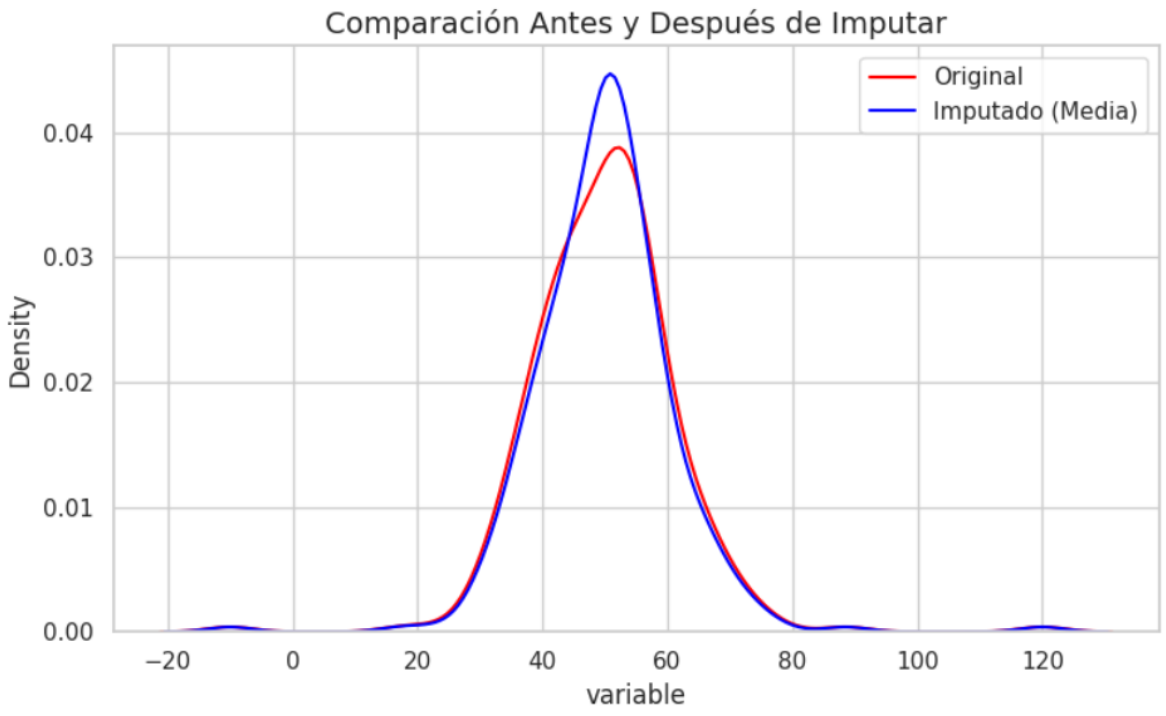

Métodos avanzados de imputación

- K-Nearest Neighbors (KNN) Imputer
- Regresión
- MICE
- Random Forest Imputer

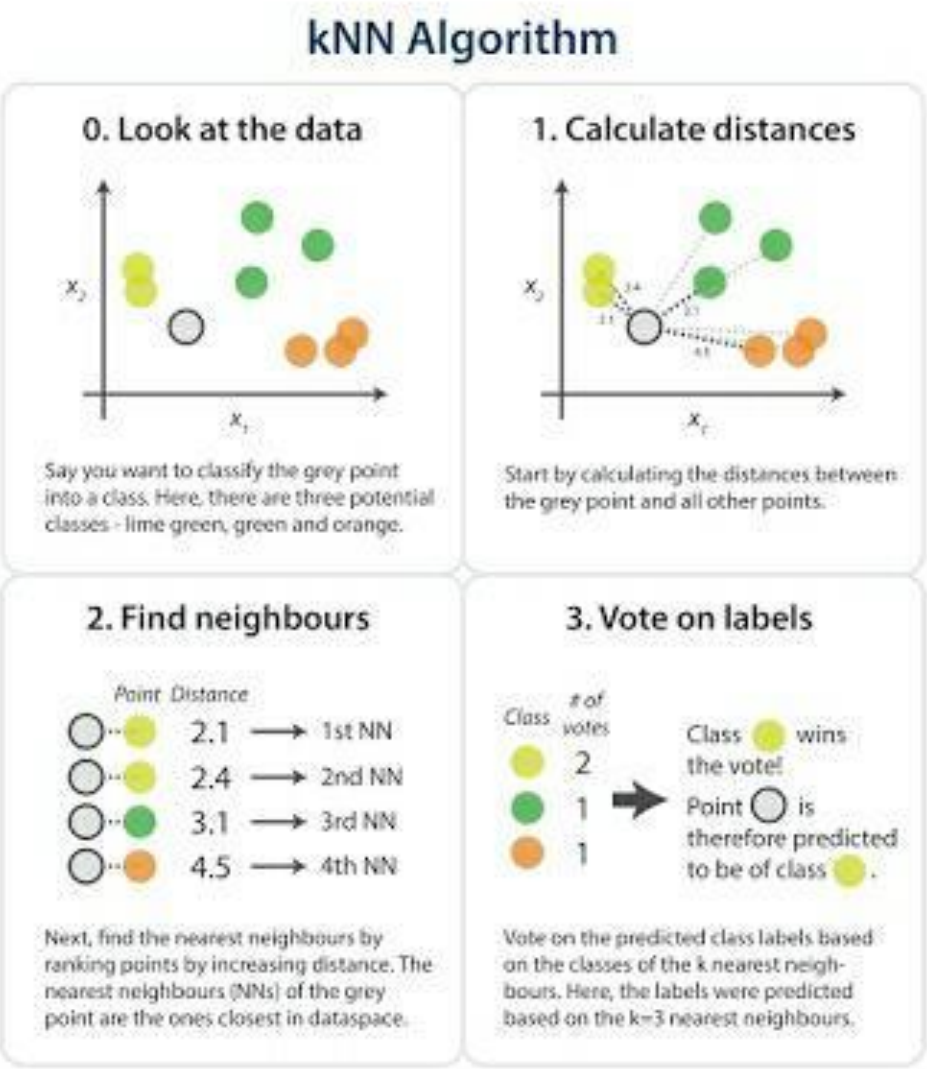

Ejemplo de Imputación por KNN

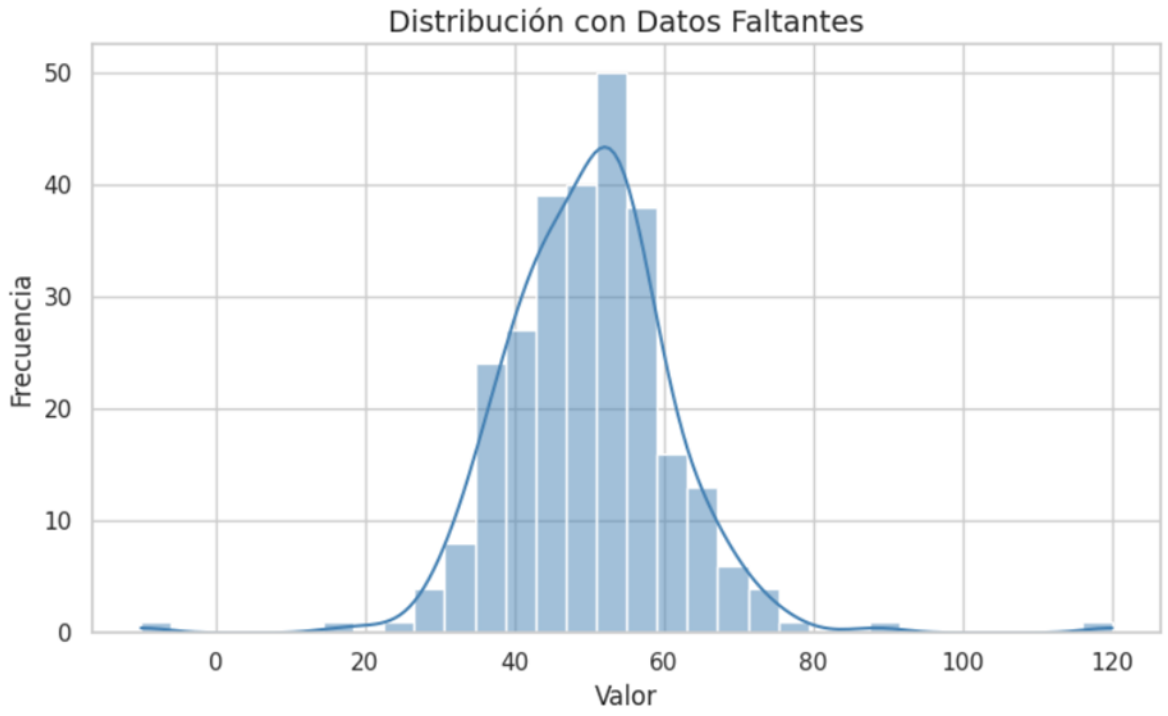

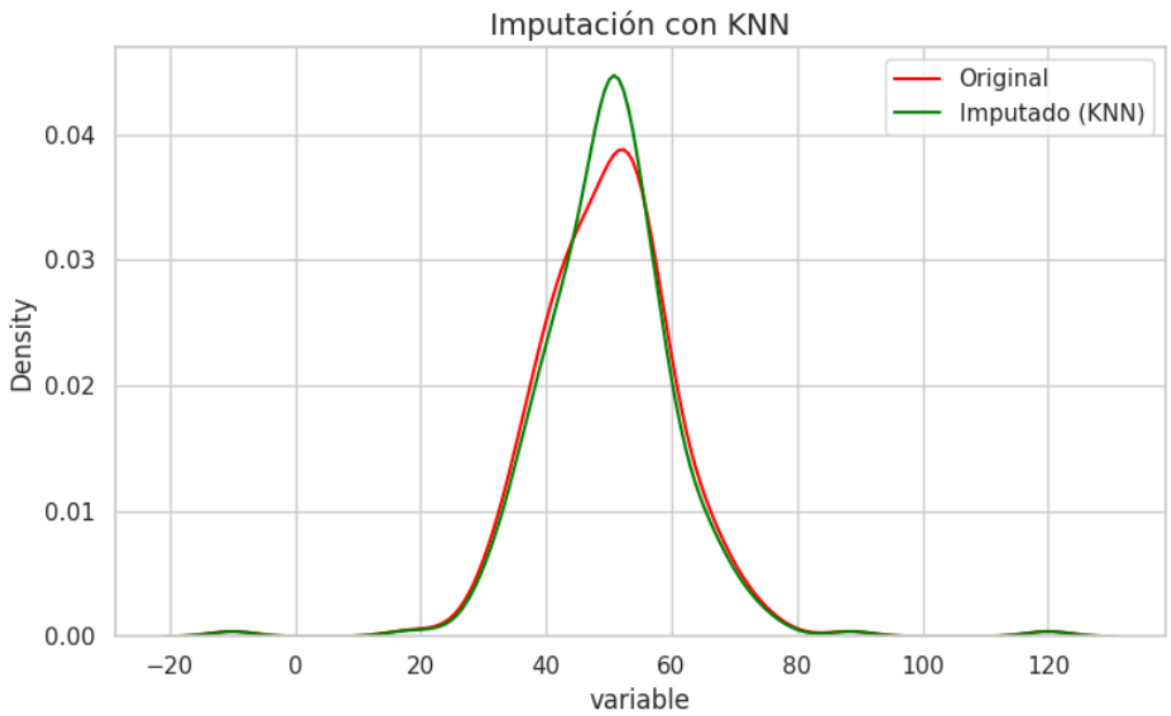

¿Qué es un valor atípico (outlier)?

- Valor que se aleja significativamente del resto.

- Puede indicar:
  - Errores
  - Variabilidad natural
  - Casos extremos

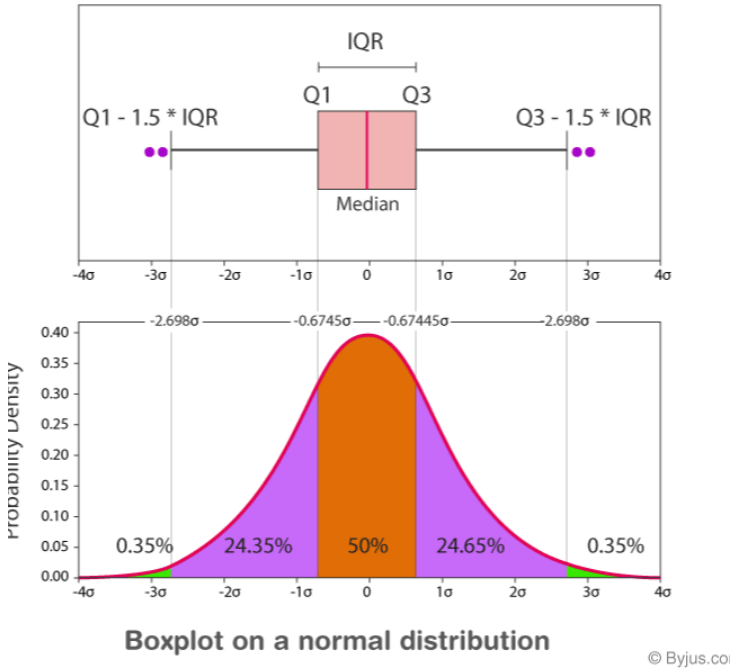

Tipos de outliers

Global

Contextual

Colectivo

Métodos para detectar outliers

Estadísticos

- IQR
- Z-score

Visuales

- Boxplots
- Histogramas
- Scatterplots

Basados en modelos

- Isolation Forest
- DBSCAN
- LOF (Local outlier factor)

Ejemplos en Python: Outliers

```python
import numpy as np
import pandas as pd

# Detección por Z-score
from scipy import stats

z_scores = np.abs(stats.zscore(df["ingresos"]))
outliers = df[z_scores > 3]

# Detección por IQR
Q1 = df["ingresos"].quantile(0.25)
Q3 = df["ingresos"].quantile(0.75)
IQR = Q3 - Q1

outliers_iqr = df[(df["ingresos"] < Q1 - 1.5*IQR) |
                  (df["ingresos"] > Q3 + 1.5*IQR)]
```

- Scipy: es una biblioteca de código abierto para Python especializada en computación científica, técnica y matemática, construida sobre NumPy.

Métodos para tratar outliers

- Eliminación
- Winsorización
- Transformaciones (log, sqrt, Box-Cox)
- Imputación
- Modelos robustos

Conclusiones

- Los datos faltantes y outliers afectan la calidad del análisis.
- No existe un método universal.
- Es esencial comprender la causa y el contexto.
- El pretratamiento adecuado mejora la precisión de los modelos.