.UBAeconómicas

METODOS PREDICTIVOS
PARA LA GESTIÓN

UNIDAD 3
Regresión Lineal Simple

TECNICATURA UNIVERSITARIA EN
GESTIÓN Y ANÁLISIS DE DATOS EN ORGANIZACIONES

DEPARTAMENTO PEDAGÓGICO DE MATEMÁTICA DPM
FACULTAD DE CIENCIAS ECONÓMICAS • UBA

CIUDAD AUTÓNOMA DE BUENOS AIRES

¿Qué es una Regresión?

Es el retroceso o la acción de volver hacia atrás.

En términos estadísticos, es un método para modelar y analizar la relación entre una **variable dependiente** (lo que queremos predecir) y una (o más) **variables independientes** (factores que influyen)

¿y un Análisis de Regresión?

El análisis de regresión es el estudio de la **dependencia** de una variable (la dependiente) respecto de una o más variables (independientes o explicativas) con el objetivo de **estimar o predecir la media** o valor promedio poblacional de la primera en términos de los valores conocidos o fijos (en muestras repetidas) de las segundas.

¿Por qué hablamos de Regresión Lineal?

Se trata de un modelo que busca **estimar el valor esperado** de una variable aleatoria en función de los valores de otra(s) con las cuales presenta **dependencia estadística** (relación no determinística), modelando dicha estructura a través de una recta.

Función de la recta:

$$y = variable\ dependiente$$

$$f(x) = y = mx + b$$

$$b = ordenada\ al\ origen$$

$$x = variable\ independiente$$

$$\mathrm{m} = perndiente$$

Esta ecuación **es determinística**. A partir de X, conocemos el valor de Y con una **precisión** absoluta.

¿Y la regresión?

Las variables INPUT (X) / OUTPUT (Y)

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon$$

β_0(Ordenada al origen): El valor base Y cuando X es cero.

β_1(Pendiente): El motor del cambio. Cuanto varía Y por cada unidad adicional de X.

ϵ (Término del error Aletorio) La incertidumbre. Lo que el modelo no puede explicar

El término del error, incluyéndose como **componente aleatorio**, es lo que lo convierte en un **modelo estocástico** (no determinístico)**.**

¿Por qué hablamos de probabilidad?

La recta por sí sola es el **promedio <u>esperado</u>**. Cuando decimos que la regresión no es determinística, estamos aceptando que para un mismo valor de X, pueden existir diferentes valores de Y, distribuidos alrededor de la recta modelada.
Entonces el modelo propone una línea recta ideal, pero el mundo se muestra como un desorden. El error no es una equivocación, es la **variabilidad natural**. Sin el ϵ, estaríamos diciendo que el modelo explica el 100% de la realidad, lo cual en la práctica es imposible.

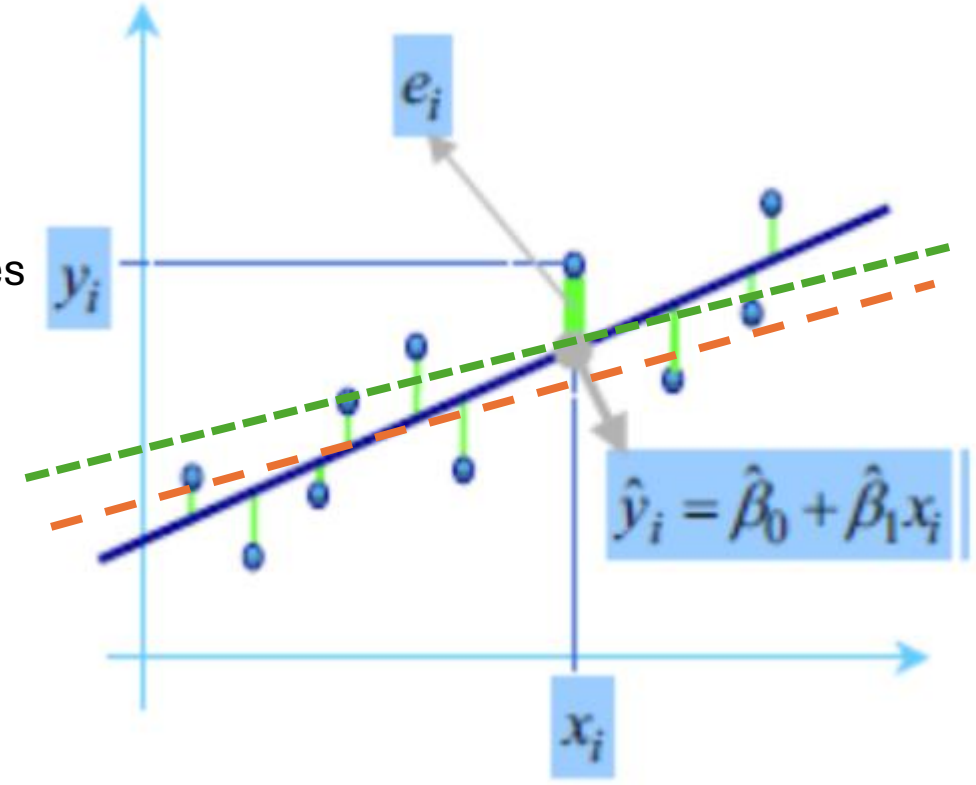

¿Ahora como sabemos que la recta ideal es esa y no esta?

¿O esta otra?

Mínimos Cuadrados Ordinarios

El objetivo del algoritmo es encontrar los valores de β_0 y β_1 que haga que la suma de los cuadrados del error $(\sum \epsilon_i^2)$ sea lo menor posible.

¿Por qué al cuadrado?

- **Problema de la cancelación:** Si fuera la suma de los errores, el resultado tendería a 0 (cero).
- Al tomar los valores al cuadrado del error y no los absolutos, se **penalizan los errores más grandes**.
  - En el valor absoluto un error de 2, es el doble de una diferencia de 1.
  - En los Mínimos cuadrados, un error de 2, pesa cuatro veces más $(2^2 = 4)$. Y un error de 10, cien veces más.

Se prefiere un modelo que cometa muchos errores chicos a uno que cometa un solo error gigante. El cuadrado "castiga" con fuerza a los puntos que están muy lejos, obligando a la recta a acercarse a ellos para minimizar esa área.

El cálculo de los coeficientes

La pendiente estará dada por:

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{Covarianza\ (XY)}{Varianza\ (X)}$$

Es decir, la proporción de cómo se mueven juntas (X e Y) vs. Como se mueve sola (X)

$$\boxed{\hat{\beta}_1 = \frac{n\sum(xy) - \sum(x)\sum(y)}{n\sum x^2 - (\sum x)^2}}$$

La ordenada al origen:
Si tomamos como premisa que la recta de mínimos cuadrados siempre pasa por el punto promedio de los datos, entonces:

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1\bar{x}. \longrightarrow \boxed{\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}}$$

Supuestos de Gaüss-Markov

Para que las predicciones generadas por el modelo sean confiables, el mismo debe cumplir con algunos requisitos. El cumplimiento de estos garantizará que el modelo se encuentre correctamente especificado:

1. Media Cero: En promedio, los errores se cancelan. Si la media de los errores fuera, por ejemplo, +5, significaría que tu modelo siempre subestima el desempeño por 5 puntos. Si eso pasa, se debería subir la recta 5 puntos (ajustando la ordenada al origen) y el error vuelve a ser cero. Es una condición del equilibrio.

2. Homocedasticidad: La dispersión del error es constante. No importa si X tiene un valor u otro, la "incertidumbre" de la predicción debe ser la misma. Si los errores aumentaran las estimaciones de precisión ya no son fiables.

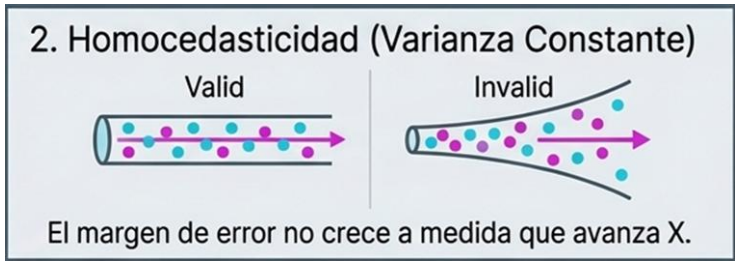

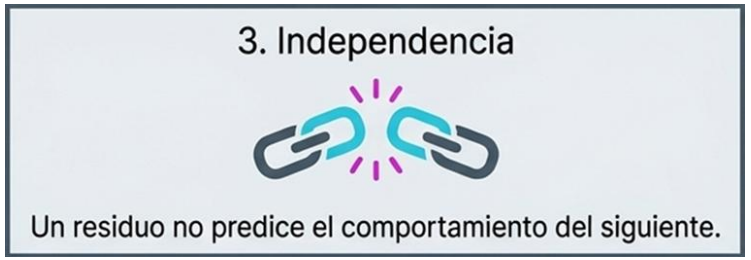

3. Independencia: Los errores son independientes entre sí. Lo que le pasa a un dato no afecta al otro. Si el error de X_1 influye en X_2, hay autocorrelación. Esto opera artificialmente en la precisión del modelo.

Supuestos de Gaüss-Markov

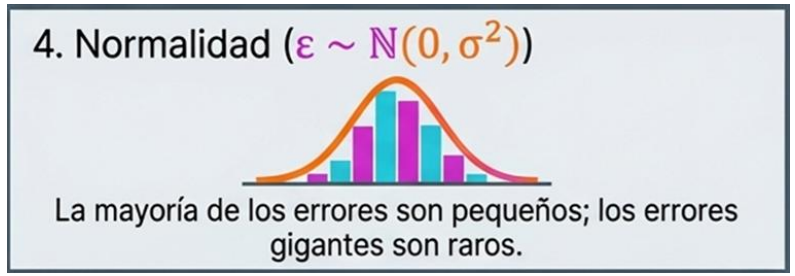

4. Normalidad: Los errores siguen la campana de Gauss. Podemos apoyarnos en las distribuciones Z o T para determinar probabilidades y confianza.

5. No Correlación con X: $Cov\ (\epsilon_i, x_i)$ = 0. El error es "ciego" a la variable explicativa. Si el error estuviera relacionado con x, el modelo termina siendo espurio. Ejemplo: Supongamos que una heladería decide invertir muchísimo en publicidad (X) justo en los meses de verano, y deja de invertir en invierno. La Regresión verá que cuando sube la publicidad, suben las ventas. Pero no tiene en cuenta el efecto del clima. Si esta Covarianza es 0, se garantiza que X no se "robe" méritos que no le corresponden.

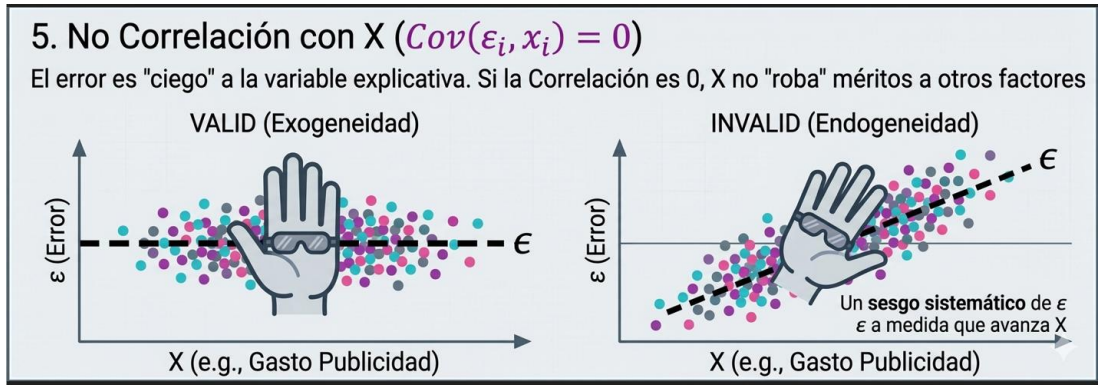

Si se cumplen estos 5 puntos, se obtiene un modelo **insesgado** y **eficiente**.
También se dice que es MELI (Mejor Estimador Lineal Insesgado)

Ejemplo

Imaginemos en una empresa que se pretende analizar si las horas de instrucción tienen incidencia en el desempeño real de los empleados. Se observan los siguientes datos:

Inst.	Horas de instrucción (x)	Desempeño Real (y)	$(y-\bar{y})^2$	(xy)	x^2	y^2
1	1	25	1036,84	25	1	625
2	2	28	852,64	56	4	784
3	3	42	231,04	126	9	1764
4	4	43	201,64	172	16	1849
5	5	50	51,84	250	25	2500
6	6	65	60,84	390	36	4225
7	7	66	77,44	462	49	4356
8	8	78	432,64	624	64	6084
9	9	80	519,84	720	81	6400
10	10	90	1075,84	900	100	8100
Sumas	**55**	**572**	**4540,6**	**3725**	**385**	**36687**

$$\boxed{\hat{\beta}_1 = \frac{n\sum(xy) - \sum(x)\sum(y)}{n\sum x^2 - (\sum x)^2}}$$

$$\hat{\beta}_1 = \frac{10(3725) - 55(572)}{10(385) - (55)^2}$$

$$\hat{\beta}_1 = \frac{37250 - 31450}{3850 - 3025}$$

$$\hat{\beta}_1 = \frac{37250 - 31450}{3850 - 3025}$$

$$\hat{\beta}_1 \approx 7{,}018$$

$$\boxed{\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}}$$

$$\hat{\beta}_0 = 57{,}2 - 7{,}02(5{,}5)$$

$$\hat{\beta}_0 = 18{,}59$$

$$\boxed{\hat{y} = 18{,}6 + 7{,}02x}$$

Ejemplo

Inst.	Horas de instrucción (x)	Desempeño Real (y)	Desempeño Esperado ($\hat{y}$)	$(y-\hat{y})$	$\epsilon=(y-\hat{y})^2$
1	1	25	**23,0**	2	4
2	2	28	**30,5**	-2,5	6,25
3	3	42	**38,0**	4	16
4	4	43	**45,5**	-2,5	6,25
5	5	50	**53,0**	-3	9
6	6	65	**60,5**	4,5	20,25
7	7	66	**68,0**	-2	4
8	8	78	**75,5**	2,5	6,25
9	9	80	**83,0**	-3	9
10	10	90	**90,5**	-0,5	0,25
Sumas	**55**	**572**		**-0,5**	**81,25**

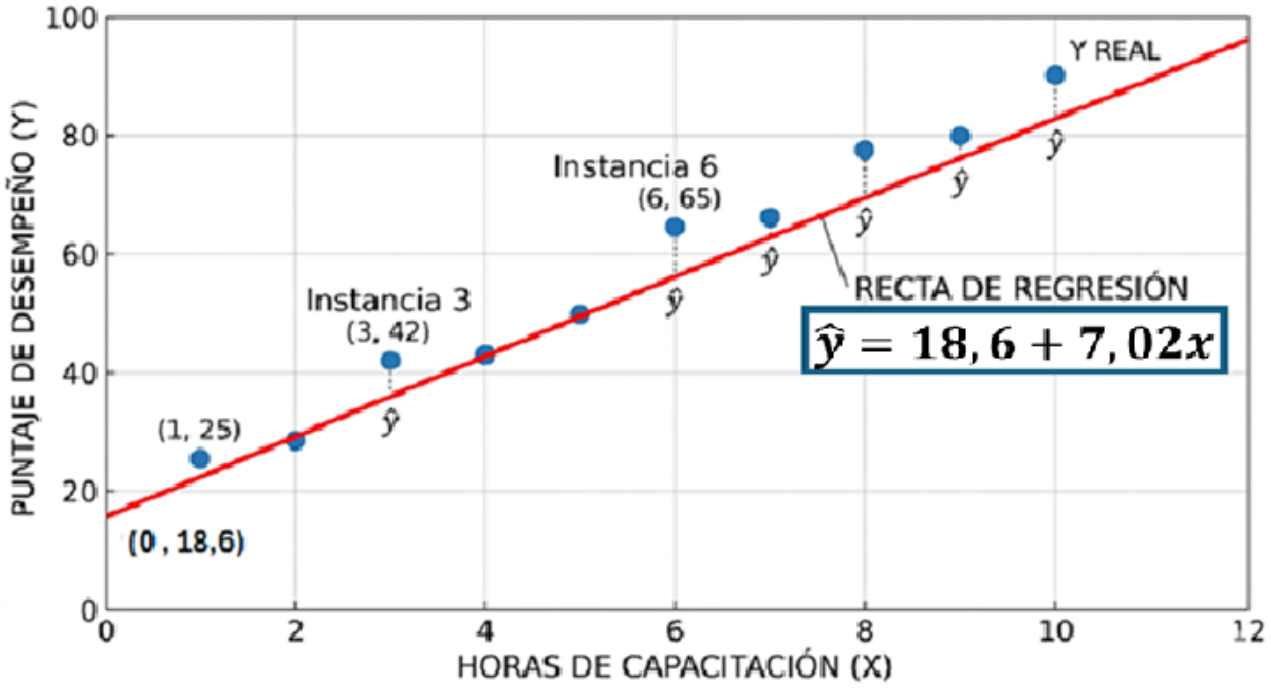

La suma de los residuos tiende a 0 (cero)

Medidas de bondad de ajuste

Antes de confiar en el modelo, se tiene que medir que tan bien ajusta. Para eso se desarma la variabilidad total de la variable y en sus dos componentes fundamentales.

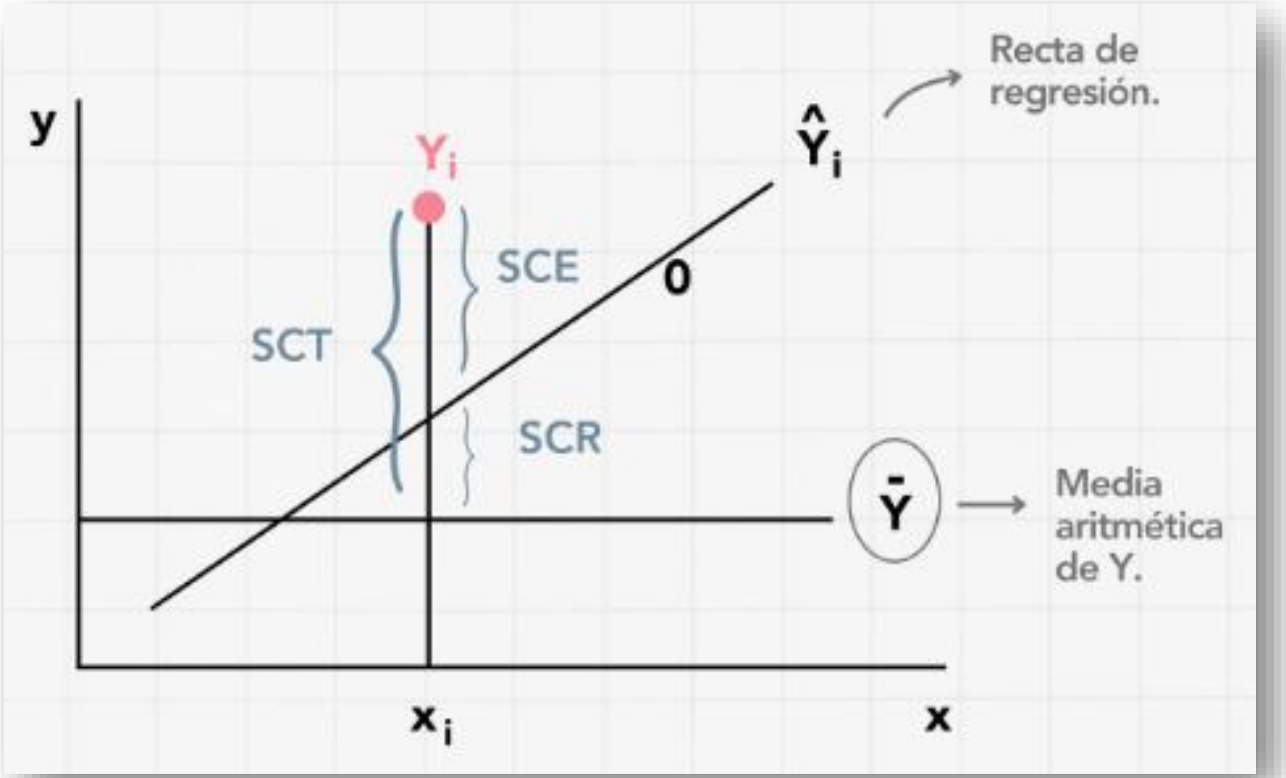

$$SCT = \sum (y_i - \bar{y})^2$$

$$SCE = \sum (y_i - \hat{y})^2$$

$$SCR = \sum (\hat{y} - \bar{y})^2$$

Coeficiente de Determinación

$$SCT = SCR + SCE$$

Cuanto mayor es la proporción SCR y menor la de SCE, más explicada estará su variabilidad. A ese coeficiente se lo denomina **Coeficiente de Determinación o R^2**

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}$$

Varianza Residual o del Modelo

Esta es una medida absoluta de que tan bien se ajusta la recta de regresión estimada a las medias de las observaciones de la variable respuesta.

$$S^2 = \frac{\boldsymbol{SCE}}{n-p} = \frac{\sum(y_i - \hat{y})^2}{n-p}$$

p =es la cantidad de parámetros que se estiman. En un caso de regresión simple los parámetros son 2: β_0y β_1

Esto no debe confundirse con la **Varianza Total**. Esté ultima mide que tan dispersos están los datos respecto del promedio. Es decir, que tan desordenados están los datos. La **varianza del modelo** mide que tanto desorden queda después de aplicar el modelo.

Coeficiente de Correlación Muestral

Brinda una medida de la relación lineal entre los X e Y. El coeficiente adquiere un valor entre -1 y 1

$$R = \frac{S_{XY}}{\sqrt{S_{XX}}\sqrt{S_{YY}}}$$

El cuadrado del coeficiente de correlación muestral da el valor del coeficiente de determinación. Es decir:

$$R = \sqrt{R^2}$$

- R=1 relación lineal perfectamente positiva. A mayor X ➔ Mayor Y (y viceversa).
- R= -1 relación lineal perfectamente negativa. A mayor X ➔ Menor Y (y viceversa).
- R=0 indica que existe una ausencia completa de relación lineal entre X e Y. No importa que suceda con X. Las variables no están relacionadas.

Correlación: Fuerza y Dirección

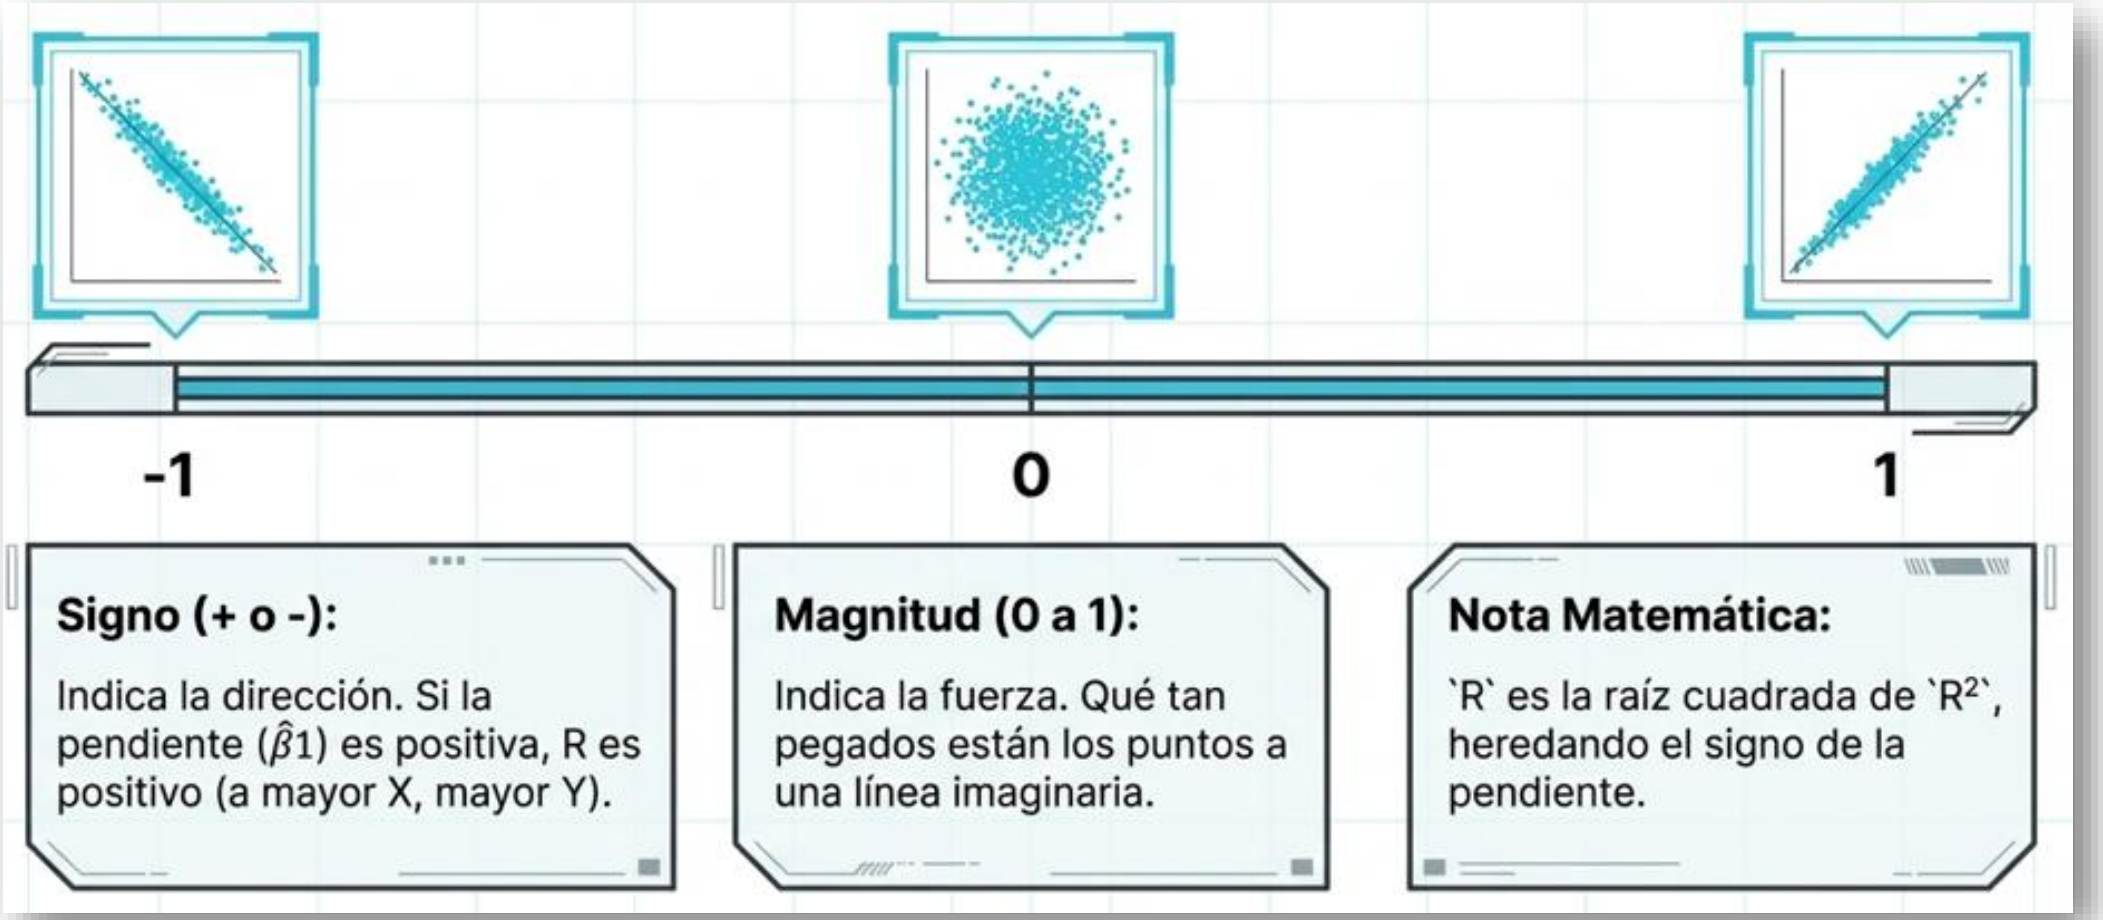

Ejemplo

Inst.	Horas de instrucción (x)	Desempeño Real (y)	(xy)	x^2	Y^2	$\hat{y}$	$(y-\hat{y})$	$\epsilon=(y-\hat{y})^2$	$(y-\bar{y})^2$
1	1	25	25	1	625	23,0	2	4	1036,84
2	2	28	56	4	784	30,5	-2,5	6,25	852,64
3	3	42	126	9	1764	38,0	4	16	231,04
4	4	43	172	16	1849	45,5	-2,5	6,25	201,64
5	5	50	250	25	2500	53,0	-3	9	51,84
6	6	65	390	36	4225	60,5	4,5	20,25	60,84
7	7	66	462	49	4356	68,0	-2	4	77,44
8	8	78	624	64	6084	75,5	2,5	6,25	432,64
9	9	80	720	81	6400	83,0	3	9	519,84
10	10	90	900	100	8100	90,5	-0,5	0,25	1075,84
Sumas	**55**	**572**	**3725**	**385**	**36687**		**-0,5**	**81,25**	**4540,6**
Promedio	**5,5**	**57,2**							

Ejemplo

$$R^2 = 1 - \frac{SCE}{SCT} \Rightarrow R^2 = 1 - \frac{81{,}25}{4540{,}6} \Rightarrow R^2 = 1 - \frac{81{,}25}{4540{,}6} \Rightarrow \boxed{R^2 = 0{,}982}$$

Con un R^2 de 0,982, se puede decir que el modelo explica el 98,2% de la variabilidad total.

$$S^2 = \frac{SCE}{n-p} \Rightarrow S^2 = \frac{81{,}25}{10-2} \Rightarrow \boxed{S^2 = 10{,}16} \Leftrightarrow$$

Vs. La varianza de los datos, nos muestra: Var(y) = 454,06

$$R = \sqrt{R^2} \Rightarrow R = \sqrt{0{,}982} \Rightarrow \boxed{R = 0{,}99}$$

Tomando el signo de la pendiente, se observa que ambas variables están fuertemente correlacionadas en forma positiva. A más horas de capacitación, mejor desempeño.

¿Es significativo nuestro hallazgo?

El último punto del análisis es determinar si la relación entre X y Y es real o producto del azar.

Entonces, si la pendiente fuera cero (β_1), la variable independiente (X) no sirve. ¿Podemos demostrar que es distinta de cero?

Comparamos nuestra pendiente calculada contra su error estándar.

p-value < 5% ➔ entonces, la relación es estadísticamente significativa.

p-value > 5% ➔ No tenemos pruebas suficientes.

Un modelo exitoso

La regresión lineal, no se trata de trazar una línea, sino validar matemáticamente que esa línea representa la verdadera estructura oculta de los datos.

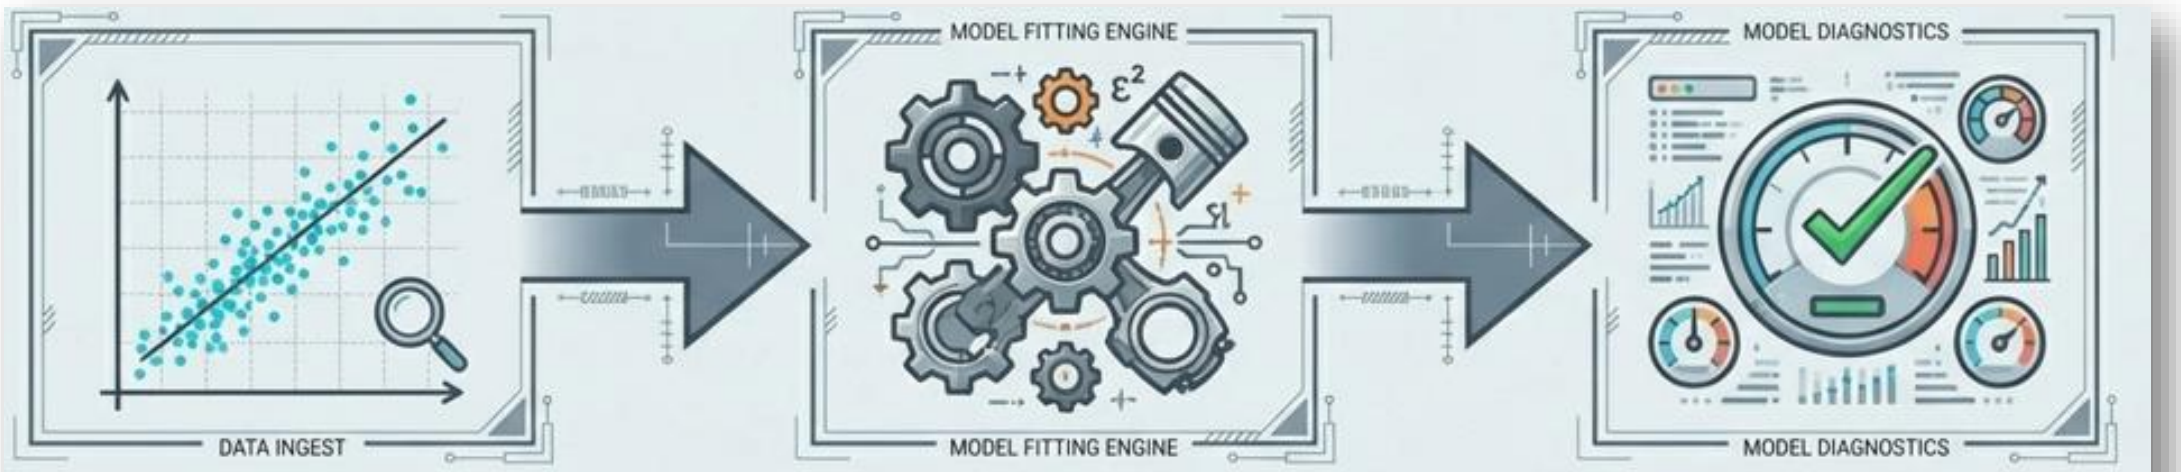

Exploración

Visualizar el caos y confirmar tendencia lineal.

Entrenamiento

OLS minimiza ε^2 para hallar $\beta 0$ y $\beta 1$ óptimos.

Validación

Chequear Gauss-Markov, evaluar R^2 y validar el **p-valor**.

.UBAeconómicas

¡Muchas gracias por su atención!

Realice las practicas del campus y cualquier consulta dirigirse al foro.